

Partie I

Contexte scientifique

Optimisation de descripteurs artisanaux et benchmark de classifieurs pour la classification de tumeurs cérébrales en IRM

Projet MSDIA — Machine Learning classique

Votre Nom

1^{er} juillet 2026

Institution / Encadrant

Contexte

Plan de la présentation

1 :00

Contexte

Données et descripteurs

Méthodologie

Résultats

Validation et conclusion

Problématique clinique et choix méthodologique

2 :00


Enjeu : distinguer gliome, méningiome et tumeur hypophysaire sur IRM conditionne le traitement [1], [2].

Difficultés ML :

- Haute dimensionnalité (16,384 pixels bruts)
- Différences subtiles de texture et d'intensité
- Variabilité d'acquisition ; besoin de métriques robustes (F1-macro)

Positionnement

ML classique + features interprétables (CPU, reproductible) vs. DL (GPU, données massives, boîte



2 :00


1. **Texture MRI** : GLCM, LBP, DWT, HOG complémentaires pour la micro-structure tumorale [4], [5], [6].
2. **Classifieurs** : SVM et forêts dominant les benchmarks radiomiques [7], [8].
3. **Sélection de paramètres** : souvent grid search couplé à *un* classifieur — risque de sur-apprentissage du couple feature/modèle [9].

Lacune identifiée

Aucune étude ne combine sélection *sans classifieur* (FDR/MI/DBI) sur GLCM+LBP+DWT+HOG avec un benchmark multi-modèles (8) et validation statistique complète sur le même split.

2 :00

1. Protocole **séparabilité d'abord** : 213 configs, métriques FDR+MI+DBI.
2. Benchmark **8 classifieurs** $\times$ **8 branches** (384 runs).
3. Analyse d'**importance par branche** (RF sur Full(opt)).
4. Validation : κ , bootstrap 95%, Wilcoxon, Friedman–Nemenyi.



Vue d'ensemble Phase 1 : sélection avant tout entraînement.

Partie II

Données et descripteurs


Données et descripteurs

2 :00



Corpus : Kaggle Brain Tumor Detection (1 500 IRM, 500/classe).

- Classes : gliome, méningiome, tumeur hypophysaire
- Split stratifié : train 1 050 + val 150 / test 300
- Prétraitement : niveaux de gris, 128×128 , CLAHE, rognage bordures

Métrique principale : F1-macro (équilibre des classes, ≈ 1.0).



Architecture du pipeline



Descripteurs de texture : GLCM et LBP

1 :30

GLCM [4] : co-occurrence des niveaux de gris

→ **6 features** Haralick (contraste, énergie...)

LBP [5] : motif binaire du voisinage

→ **10 dimensions** (histogramme uniforme)




Illustration des quatre familles sur une coupe prétraitée.

Structure et forme : DWT et HOG


1 :30

DWT [10] : sous-bandes multi-échelle (LL, LH, HL, HH)

→ **16 features** (moyenne, énergie, entropie)

HOG [7] : histogrammes d'orientations de gradient

→ **1 176 dimensions** sur 128×128



Phase 1 — scores de séparabilité HOG (top configs).

Méthodologie

2 :00 Pour chaque configuration c , on calcule sur le train :

$$\text{FDR} = \frac{1}{p} \sum_{j=1}^p \frac{\sigma_B^2(j)}{\sigma_W^2(j) + \varepsilon} \quad (\text{plus haut} = \text{mieux})$$

$$\text{MI}(X_j; Y) = \sum_{x,y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \quad (\text{dépendance non-linéaire})$$

$$\text{Score}(c) = \frac{\text{FDR}_n + \text{MI}_n + (1 - \text{DBI}_n)}{3}$$

Avantage : rapide, sans fuite vers le classifieur, 213 configs évaluées.

Partie III

Méthodologie expérimentale



Paramètres optimaux retenus (Phase 1)

1 :00

Feature	Meilleurs params	FDR	MI	DBI	Dim.	Score
GLCM	$d=[1, 2, 4, 8]$; $\theta=0$; $L=128$; sym.	0.313	0.196	4.03	6	0.781
LBP	$P=8$; $R=1$; uniform	0.196	0.111	2.85	10	1.000
DWT	bior1.3; niveau = 1	0.193	0.104	3.99	16	0.994
HOG	6 orient.; cell. (16, 16); blocs (2, 2)	0.021	0.025	6.63	1 176	0.997

Grilles de recherche Phase 1

1 :30



2 :00


8 branches : A (Stats), B (Tex), C (DWT), D (HOG)

+ fusions A+B, B+C, A+B+C,

Full(opt)

Nettoyage post-fusion :

- Standardisation (StandardScaler)
- Suppression NaN / constantes / faible variance
- Élagage des corrélations redondantes



2 :00

8 classifieurs :

- **Linéaires / noyau** : SVM (RBF), LR
- **Instance** : KNN
- **Ensembles** : RF, Extra Trees, XGBoost, LightGBM
- **Réseau** : MLP

Évaluation : 1 split hold-out + CV 5-fold
stratifiée

⇒ **384 expériences** ($8 \times 8 \times 6$)

Fold 1
Fold 2
Fold 3
Fold 4
Fold 5

test rotatif

Partie IV

Résultats

Résultats

Performance par branche (split test)

2 :00

Branche	Modèle	F1-macro	Accuracy
A — Stats	SVM	0.787	78.7%
B — Tex(opt)	XGBoost	0.827	82.7%
C — DWT(opt)	ExtraTrees	0.763	76.3%
D — HOG	SVM	0.903	90.3%
A+B	ExtraTrees	0.850	85.0%
B+C(opt)	XGBoost	0.853	85.3%
A+B+C(opt)	RF	0.857	85.7%
Full(opt)	SVM	0.920	92.0%

Table 1: Meilleure combinaison modèle/branche sur le split test (hold-out).

Observation : D — HOG seul (0.903) approche Full(opt) (0.920) ; C — DWT(opt) reste le bloc le plus faible (0.763)

Classement des meilleures configurations

1 :30



Rang	Feature set / Modèle	F1-macro	Acc.	κ
1	Full(opt) / SVM	0.920	92.0%	0.88
2	D — HOG / SVM	0.903	90.3%	0.855
3	Full(opt) / KNN	0.900	90.0%	0.85
4	D — HOG / KNN	0.897	89.7%	0.845
5	Full(opt) / LightGBM	0.894	89.3%	0.84

Table 2: Top 5 configurations (split test, tri par F1-macro). IC 95% : Full+SVM [0.890, 0.950].

Vue d'ensemble Phase 2

1 :30

Overall Dashboard — Optimal Feature Parameters + Model Benchmark




Analyse d'importance des branches

2 :00

RF sur Full(opt) : importance cumulée par groupe de features.

- HOG domine en importance brute (dimensionnalité)
- GLCM/Stats : fort signal par dimension
- Fusion : $\Delta F1 = 0.017$ vs. HOG seul

⇒ stratégie *sélective* plutôt qu'agrégation aveugle.



Importance par branche (Random Forest, Full(opt)).


Matrice de confusion — Full(opt) + SVM

1 :30

Résultat principal :

- F1-macro : **0.920**
- Accuracy : 92.0%
- Cohen's κ : 0.88

Pipeline end-to-end : IRM → features → nettoyage → SVM.



Matrice de confusion sur le split test ($n=300$).

Partie V

Validation et conclusion

Validation et conclusion


2 :00

Bootstrap 95% CI (F1-macro) :

- Full(opt)+SVM : [0.890, 0.950], $\kappa=0.88$
- D—HOG+SVM : [0.868, 0.935],
 $\kappa=0.855$

Tests complémentaires :

- Friedman (Full) : $p=0.022$ — différences inter-modèles significatives
- Full vs HOG : IC qui se chevauchent ($\Delta F1 = 0.017$)



IC bootstrap 95% — meilleures branches.

2 :00

Limites

- Split unique (80/20); généralisation multi-centre non testée
- Corpus Kaggle : variabilité d'acquisition limitée
- Pas de comparaison DL dans ce travail (scope ML classique)
- Fusion : gain marginal ($\Delta F1 = 0.017$)

Perspectives

- Comparaison contrôlée ML vs CNN hybrides (Phase 3)
- Sélection HOG par PCA / importance
- Validation externe sur cohorte clinique
- Extension binaire (tumeur / sain)

1 :30 Synthèse

1. Pipeline séparabilité $\rightarrow$ benchmark : **F1-macro = 0.920**, $\kappa = 0.88$
2. Sélection FDR/MI/DBI : 213 configs sans classifieur, reproductible
3. HOG seul (0.903) compétitif; fusion utile mais marginale (+0.017 F1)

Le ML classique bien ingéniéré reste une alternative crédible et interprétable.

Références

- [1] U. BHIMAVARAPU et al., « Brain Tumor Detection and Categorization with Segmentation of Improved Unsupervised Clustering Approach and Machine Learning Classifier, » *Bioengineering*, t. 11, n° 3, p. 266, 2024. DOI : [10.3390/bioengineering11030266](https://doi.org/10.3390/bioengineering11030266)
- [2] M. OTTONI et al., « Machine Learning in MRI Brain Imaging : A Review of Methods, Challenges, and Future Directions, » *Diagnostics*, t. 15, n° 21, p. 2692, 2025. DOI : [10.3390/diagnostics15212692](https://doi.org/10.3390/diagnostics15212692)

- [3] F. ALSHOMRANI, « **Challenges and Advances in Classifying Brain Tumors : An Overview of Machine, Deep Learning, and Hybrid Approaches,** » *IEEE Access*, 2025. DOI : [10.1109/ACCESS.2025.3579727](https://doi.org/10.1109/ACCESS.2025.3579727)
- [4] G. DHEEPAK et al., « **Brain tumor classification : a novel approach integrating GLCM, LBP and composite features,** » *Frontiers in Oncology*, t. 13, p. 1248452, 2024. DOI : [10.3389/fonc.2023.1248452](https://doi.org/10.3389/fonc.2023.1248452)
- [5] Y. YU et al., « **Characterizing Brain Tumor Regions Using Texture Analysis in Magnetic Resonance Imaging,** » *Frontiers in Neuroscience*, t. 15, p. 634926, 2021. DOI : [10.3389/fnins.2021.634926](https://doi.org/10.3389/fnins.2021.634926)
- [6] S. AHMED MEDJAHED, « **A Comparative Study of Feature Extraction Methods in Images Classification,** » *International Journal of Image, Graphics and Signal Processing*, t. 7, n° 3, p. 16-23, 2015. DOI : [10.5815/ijigsp.2015.03.03](https://doi.org/10.5815/ijigsp.2015.03.03)

- [7] M. BASTHIKODI et al., « **Enhancing multiclass brain tumor diagnosis using SVM and innovative feature extraction techniques**, » *Scientific Reports*, t. 14, n° 1, p. 26 023, 2024. DOI : 10.1038/s41598-024-77243-7
- [8] A. A. ASIRI et al., « **Machine Learning-Based Models for Magnetic Resonance Imaging (MRI)-Based Brain Tumor Classification**, » *Intelligent Automation & Soft Computing*, t. 36, n° 1, p. 299-312, 2023. DOI : 10.32604/iasc.2023.032426
- [9] K. KUMAR et K. JYOTI, « **Machine learning for brain tumor classification : evaluating feature extraction and algorithm efficiency**, » *Discover Artificial Intelligence*, t. 4, n° 1, p. 112, 2024. DOI : 10.1007/s44163-024-00214-4

- [10] M. JAFARI, M. RAHMANI et al., « **Hybrid Radiomics and Machine Learning for Brain Tumors Multi-Task Classification,** » *Health Science Reports*, t. 8, n° 8, e71195, 2025. DOI : 10.1002/hsr2.71195