

Classification de tumeurs cérébrales en IRM par apprentissage automatique classique

Optimisation de descripteurs, benchmark de classifieurs et validation
statistique

[Nom de l'étudiant]

MSDIA S8 — Projet 7
Juillet 2026

Résumé

Le diagnostic des tumeurs cérébrales repose sur la distinction entre gliome, méningiome et tumeur hypophysaire à partir d'images IRM — une tâche essentielle pour la planification thérapeutique, mais chronophage lorsqu'elle est réalisée manuellement. Ce rapport présente un pipeline d'apprentissage automatique en deux phases conçu pour classifier des IRM de tumeurs cérébrales à l'aide de descripteurs artisanaux optimisés. En Phase 1, nous effectuons une recherche de paramètres guidée par la séparabilité sur 213 configurations de quatre familles de descripteurs (statistiques, motifs binaires locaux — LBP, transformée en ondelettes discrète — DWT, et histogrammes de gradients orientés — HOG), en sélectionnant la meilleure configuration par famille sans entraîner de classifieur. En Phase 2, les jeux de caractéristiques optimisés et leurs fusions sont comparés à 8 classifieurs ajustés par validation croisée à 5 plis, soit 64 combinaisons évaluées. Le meilleur pipeline — Full(opt) + SVM à noyau polynomial — atteint une précision de 92.0% et un F1-macro de 0.9204 (IC bootstrap 95 % : [0.8895, 0.9504]) sur un jeu de données équilibré de 1 500 échantillons. La validation statistique (test de McNemar, test de Friedman et analyse de stabilité par graine aléatoire) confirme la robustesse des résultats. L'ensemble du pipeline s'exécute sur CPU, sans apprentissage profond, et produit des descripteurs interprétables adaptés à l'aide à la décision clinique.

Table des matières

1.1	Périmètre et motivation	4
1.2	Contributions	4
2	Jeu de données	5
2.1	Vue d'ensemble	5
2.2	Équilibre des classes	5
2.3	Choix des métriques d'évaluation	5
3	Prétraitement	6
4	Méthodes d'extraction de caractéristiques	6
4.1	A — Caractéristiques statistiques (distribution d'intensité)	6
4.2	B — Motifs binaires locaux (LBP)	7
4.3	C — Transformée en ondelettes discrète (DWT)	7
4.4	D — Histogrammes de gradients orientés (HOG)	7
5	Phase 1 : Optimisation des caractéristiques	8
5.1	Stratégie	8
5.2	Optimisation du LBP	9
5.3	Optimisation de la DWT	9
5.4	Optimisation du HOG	10
5.5	Synthèse de la Phase 1	10
6	Phase 2 : Protocole de benchmark	11
6.1	Jeux de caractéristiques	11
6.2	Classifieurs	11
6.3	Protocole d'évaluation	12
7	Résultats	12
7.1	Familles de caractéristiques individuelles	12
7.2	Jeux de caractéristiques fusionnés	13
7.3	Classement global	13
8	Analyse d'interprétabilité	15
8.1	Importance des caractéristiques	15
8.2	Visualisation de l'espace des caractéristiques	16
9	Validation statistique	17
9.1	Validation croisée	17
9.2	Stabilité par graine aléatoire	18
9.3	Intervalles de confiance bootstrap	18
9.4	Tests de significativité	19

9.4.1	Test de McNemar (comparaison par paires sur Full(opt))	19
9.4.2	Test de Friedman	19
10	Discussion	20
10.1	Pourquoi l'optimisation des caractéristiques aide	20
10.2	Pourquoi le SVM performe le mieux	20
10.3	Limites	20
10.4	Implications pratiques	21
11	Conclusion et perspectives	21
11.1	Synthèse	21
11.2	Perspectives	21
	Références	23

Introduction

Les tumeurs cérébrales comptent parmi les pathologies neurologiques les plus graves. Leur classification précise et rapide en gliome, méningiome et tumeur hypophysaire est indispensable pour orienter les décisions chirurgicales et thérapeutiques [1]. L'imagerie par résonance magnétique (IRM) constitue la modalité diagnostique de référence, mais l'interprétation manuelle par les radiologues reste chronophage et sujette à une variabilité inter-observateur.

L'apprentissage automatique offre une voie prometteuse vers des pipelines de classification automatisés et reproductibles. Si les modèles d'apprentissage profond (CNN) rapportent des performances élevées sur de grands jeux de données [2], le ML classique avec descripteurs artisanaux reste compétitif sur des corpus modestes et, surtout, offre une interprétabilité : les caractéristiques utilisées pour la classification sont explicitement compréhensibles par l'opérateur.

Périmètre et motivation

Ce travail se concentre exclusivement sur le ML classique avec descripteurs artisanaux. Nous ne détaillons pas les dérivations mathématiques des algorithmes ; l'accent est mis sur la méthodologie expérimentale et les résultats obtenus. Les questions principales sont les suivantes :

- Quels paramètres de descripteurs séparent le mieux les trois classes tumorales ?
- La fusion de plusieurs familles de caractéristiques améliore-t-elle une famille isolée ?
- Quel classifieur tire le plus de profit des caractéristiques optimisées ?
- Les résultats sont-ils reproductibles et statistiquement significatifs ?

Contributions

1. Un cadre d'optimisation de paramètres guidé par la séparabilité pour des descripteurs IRM artisanaux, explorant 213 configurations sans entraînement de classifieur.
2. Un benchmark complet de 8 classifieurs sur 8 jeux de caractéristiques, soit 64 pipelines évalués.
3. Une validation statistique multicouche (validation croisée, intervalles de confiance bootstrap, test de McNemar, test de Friedman, stabilité par graine).
4. L'identification du meilleur pipeline : **Full(opt) + SVM** avec 92.0% de précision.

Jeu de données

Vue d'ensemble

Nous utilisons un jeu de données IRM de tumeurs cérébrales publiquement disponible, contenant 1 500 images réparties équitablement entre 3 classes : **gliome**, **méningiome** et **tumeur hypophysaire** (Tableau 1).

Table 1 – Synthèse du jeu de données.

Propriété	Valeur
Nombre de classes	3 (gliome, méningiome, hypophysaire)
Nombre total d'images	1 500
Échantillons par classe	500
Partition d'entraînement	1 200 (80 %, stratifiée)
Partition de test	300 (20 %, stratifiée)
Échantillons de test par classe	100
Taille d'image (après prétraitement)	128 × 128 niveaux de gris
Graine aléatoire	42

Équilibre des classes

Le jeu de données est parfaitement équilibré : chaque classe contribue de manière égale aux partitions d'entraînement et de test. Cette conception élimine le biais lié au déséquilibre des classes et garantit que les métriques macro-moyennées reflètent directement la capacité de discrimination par classe, sans être biaisées par une classe dominante (Figure 1).




Figure 1 – Répartition des classes dans la partition d'entraînement. Chaque classe compte 400 échantillons d'entraînement.

Choix des métriques d'évaluation

Compte tenu de l'équilibre des classes, nous utilisons le **F1-macro** comme métrique principale de classement. Elle accorde un poids égal aux trois types tumoraux et mesure directement la capacité du pipeline à distinguer chaque classe. La précision (accuracy) et le κ de Cohen sont rapportés comme métriques secondaires.

Prétraitement

Toutes les images passent par le pipeline déterministe suivant avant toute extraction de caractéristiques :

1. **Conversion en niveaux de gris et mise à l'échelle.** Les images RGB sont converties en niveaux de gris ; les intensités sont ramenées à $[0, 1]$.
2. **Recadrage des bordures noires.** Les zones sombres autour de la région cérébrale sont détectées et supprimées pour se concentrer sur le contenu anatomique.
3. **Redimensionnement à 128×128 .** Les images sont rééchantillonnées avec anti-crênelage, réduisant la dimensionnalité tout en préservant les textures fines.
4. **Lissage gaussien ($\sigma = 0,5$).** Un filtre passe-bas atténue le bruit haute fréquence introduit lors de l'acquisition ou du redimensionnement.
5. **Normalisation par image et CLAHE.** Chaque image est normalisée min-max individuellement, puis une égalisation adaptative de l'histogramme à contraste limité (CLAHE, clip limit = 0,02) améliore le contraste local.

Cette séquence de prétraitement standardise la plage d'intensités entre patients et appareils, et met en évidence les structures locales pertinentes pour les descripteurs de texture et de gradient. La Figure 2 montre un exemple de coupe prétraitée.



Figure 2 — Exemple de coupe IRM prétraitée (classe méningiome), 128×128 , après amélioration CLAHE.

Méthodes d'extraction de caractéristiques

Quatre familles de descripteurs complémentaires sont extraites de chaque image prétraitée. Chacune capture un aspect distinct de l'apparence tumorale.

A — Caractéristiques statistiques (distribution d'intensité)

Onze statistiques du premier ordre sont calculées à partir de l'histogramme d'intensités des pixels : moyenne, écart-type, variance, entropie de Shannon, asymétrie, kurtosis et cinq percentiles (p10, p25, p50, p75, p90). Elles fournissent un résumé compact de la distribution globale d'intensité, sans structure spatiale.

B — Motifs binaires locaux (LBP)

Le LBP encode la texture locale en comparant chaque pixel à son voisinage circulaire de P voisins au rayon R . La méthode d'encodage détermine le regroupement en histogramme. Le LBP capture les micro-motifs de texture liés à l'hétérogénéité tissulaire tumorale.

C — Transformée en ondelettes discrète (DWT)

Une DWT 2D à un niveau décompose l'image en quatre sous-bandes (LL, LH, HL, HH) représentant respectivement la structure grossière et les détails haute fréquence horizontaux, verticaux et diagonaux. Des statistiques sont extraites de chaque sous-bande, fournissant une information multi-échelle dans le domaine fréquentiel.

D — Histogrammes de gradients orientés (HOG)

Le HOG capture la distribution des magnitudes et orientations des gradients locaux en divisant l'image en cellules et en calculant des histogrammes d'orientation, puis en normalisant sur des blocs chevauchants. Le HOG est bien établi pour la discrimination basée sur la forme et les contours.

La Figure 3 illustre les quatre types de descripteurs appliqués à une même coupe IRM.


Handcrafted descriptors on one brain-tumour MRI (Phase 1 optimal hyperparameters)

Figure 3 — Descripteurs artisanaux calculés à partir d’une coupe IRM prétraitée (méningiome). Haut : coupe prétraitée. Ligne du milieu (gauche à droite) : matrice de co-occurrence GLCM, carte LBP, carte d’énergie HOG. Ligne du bas : sous-bandes DWT (LL, LH, HL, HH).

Phase 1 : Optimisation des caractéristiques

Stratégie

Le LBP, la DWT et le HOG exposent chacun des hyperparamètres ajustables. Entraîner un classifieur complet pour chaque combinaison nécessiterait des milliers de modèles. À la place, nous classons les configurations de paramètres à l’aide de trois *métriques de séparabilité* calculées directement sur les vecteurs de caractéristiques, sans entraînement de classifieur :

- **Ratio de Fisher (FDR)** : rapport de la variance inter-classe sur la variance intra-classe.
- **Information mutuelle (MI)** : dépendance statistique entre caractéristiques et étiquettes de classe.
- **Indice de Davies–Bouldin (DBI)** : chevauchement des clusters dans l’espace

des caractéristiques (plus bas est meilleur ; nous l'invertissons avant agrégation).

Un score composite est obtenu par normalisation min-max de chaque métrique sur la grille, puis moyennage :

$$\text{Score} = \frac{1}{3} \left(\widehat{\text{FDR}} + \widehat{\text{MI}} + (1 - \widehat{\text{DBI}}) \right)$$

La configuration atteignant le score composite le plus élevé par famille de descripteur est figée pour toutes les expériences de Phase 2. L'espace de recherche total couvre 213 configurations.

Optimisation du LBP

La grille de recherche couvrait les voisins $P \in \{4, 8, 12, 16\}$, le rayon $R \in \{1, 2, 3\}$ et trois méthodes d'encodage (**uniform**, **nri_uniform**, **ror**). La Figure 4 présente le paysage de séparabilité.




Figure 4 – Recherche de paramètres LBP : score de séparabilité selon la configuration. La meilleure configuration ($P=12$, $R=1$, **uniform**) atteint un score de 0.991.

Parmi les méthodes d'encodage, **uniform** surpasse systématiquement les alternatives pour tous les couples (P, R) (Figure 5). L'histogramme compact des motifs à transitions limitées réduit le bruit et améliore la généralisation entre patients.




Figure 5 – Comparaison des méthodes d'encodage LBP. L'encodage **uniform** obtient la meilleure séparabilité pour la plupart des combinaisons de paramètres.

Optimisation de la DWT

Sept familles d'ondelettes (haar, db1, db2, db4, sym2, coif1, bior1.3) aux niveaux $\{1, 2, 3\}$ ont été évaluées (21 configurations). La Figure 6 présente les résultats.




Figure 6 – Recherche de paramètres DWT selon les familles d’ondelettes et les niveaux de décomposition. db2 au niveau 1 atteint la meilleure séparabilité (0.984).

Une comparaison directe des familles d’ondelettes (Figure 7) confirme que db2 offre le meilleur compromis : elle capture les motifs tissulaires tumoraux en moyenne fréquence sans sur-fragmenter le signal comme le font les familles plus complexes.




Figure 7 – Comparaison des familles d’ondelettes au niveau de décomposition optimal. db2 surpasse les familles plus simples (haar) et plus complexes (bior1.3).

Optimisation du HOG

Le HOG a été exploré sur 12 configurations variant le nombre d’orientations (6/9), la taille des cellules (8/16 pixels) et la taille des blocs (2/3 cellules). Une configuration avec 6 orientations, cellules (16 × 16), blocs (3 × 3) et normalisation L2-Hys a atteint la séparabilité la plus élevée (0.990).

Synthèse de la Phase 1

Le Tableau 2 rapporte les paramètres retenus et leurs scores de séparabilité. La Figure 8 fournit une synthèse visuelle.

Table 2 – Paramètres retenus en Phase 1 et scores de séparabilité.

Descripteur	Meilleurs paramètres	Score	Branche
Statistiques	11 first-order intensity features	—	A
LBP	$P=12$, $R=1$, uniform	0.991	B
DWT	db2, level = 1	0.984	C
HOG	6 orient.; cell (16, 16); block (3, 3); L2-Hys	0.990	D




Figure 8 – Synthèse de l’optimisation Phase 1 pour les quatre familles de descripteurs.

Les descripteurs de texture (LBP) et de gradient (HOG) atteignent des scores de séparabilité quasi parfaits, ce qui en fait les branches individuelles les plus fortes. Les statistiques offrent une base légère ; la DWT apporte une information fréquentielle complémentaire.

Phase 2 : Protocole de benchmark

Jeux de caractéristiques

À partir des paramètres optimisés en Phase 1, nous définissons huit jeux de caractéristiques (Tableau 3). Les jeux mono-famille (A–D) évaluent chaque descripteur isolément ; les jeux combinés testent si la fusion ajoute une valeur discriminante.

Table 3 – Jeux de caractéristiques évalués en Phase 2.

Label	Contenu	Dim. nettoyée
A — Stats	Statistiques du premier ordre uniquement	9
B — Tex(opt)	Texture LBP optimisée	18
C — DWT(opt)	Statistiques des sous-bandes DWT optimisées	12
D — HOG	Histogrammes HOG forme/contours	490
A+B	Statistiques + LBP	27
B+C(opt)	LBP + DWT	30
A+B+C(opt)	Statistiques + LBP + DWT	36
Full(opt)	Les quatre familles (A+B+C+D)	526

Chaque jeu de caractéristiques subit un nettoyage post-concaténation : un filtre de variance supprime les caractéristiques quasi nulles, suivi d’un élagage par corrélation (seuil $r > 0,95$), puis d’une normalisation StandardScaler dans chaque Pipeline sklearn.

Classifieurs

Huit classifieurs ont été benchmarkés :

Table 4 – Classifieurs et leur rôle dans le benchmark.

Famille	Classifieur	Propriété clé
Marge / noyau	SVM (RBF / polynomial)	frontières non linéaires
Basé sur instances	KNN	distances locales, sans entraînement
Arbres bagués	Random Forest, ExtraTrees	réduction de variance par ensemble
Arbres boostés	XGBoost, LightGBM	correction séquentielle des erreurs
Linéaire	Régression logistique	référence rapide et interprétable
Réseau peu profond	MLP (deux couches cachées)	activation non linéaire

Protocole d'évaluation

Chaque classifieur est ajusté par **GridSearchCV** à **5 plis** sur l'ensemble d'entraînement, puis évalué sur la partition de test tenue à l'écart. Six modes d'évaluation ont été suivis ; les résultats principaux rapportés ici correspondent à la partition de test. Cela donne $8 \text{ classifieurs} \times 8 \text{ jeux de caractéristiques} = \mathbf{64 \text{ pipelines}}$.

Métrique principale : F1-macro. Métriques secondaires : précision (accuracy), précision et rappel macro-moyennés, et κ de Cohen.

Résultats

Familles de caractéristiques individuelles

La Figure 9 présente les résultats du benchmark pour chaque jeu mono-famille. Parmi les quatre, **D — HOG + SVM** obtient la meilleure performance individuelle (90.3%, F1-macro 0.9032), suivi de **B — LBP** (82.7%), **A — Stats** (78.7%) et **C — DWT** (75.7%).




Figure 9 — Résultats du benchmark Phase 2 pour les familles de caractéristiques individuelles.

Jeux de caractéristiques fusionnés

La fusion progressive des caractéristiques améliore systématiquement les performances (Figure 10). Le gain est le plus marqué lorsque le HOG est inclus dans le jeu complet.





Figure 10 — Résultats du benchmark Phase 2 pour les jeux de caractéristiques combinés.

Classement global

Le Tableau 5 rapporte les cinq meilleures configurations. Le diagramme en barres complet est présenté à la Figure 11.

Table 5 – Top 5 des configurations classées par F1-macro sur le test tenu à l'écart.

Rang	Jeu de caract.	Classifieur	F1-macro	Précision	κ
1	Full(opt)	SVM	0.9204	92.0%	0.880
2	D — HOG	SVM	0.9032	90.3%	0.855
3	Full(opt)	KNN	0.9002	90.0%	0.850
4	D — HOG	KNN	0.8967	89.7%	0.845
5	Full(opt)	LightGBM	0.8938	89.3%	0.840

**Figure 11** – Diagramme en barres du classement de toutes les configurations évaluées, triées par F1-macro. Full(opt) + SVM est le pipeline le mieux classé.

Le tableau de bord global (Figure 12) synthétise le F1-macro, le temps d'entraînement et la variabilité par jeu de caractéristiques pour tous les classifieurs.

Overall Dashboard — Optimal Feature Parameters + Model Benchmark




Figure 12 — Tableau de bord Phase 2 : F1-macro et temps d'entraînement pour tous les jeux de caractéristiques et classifieurs.

Analyse d'interprétabilité

Importance des caractéristiques

Pour comprendre quelles familles de descripteurs pilotent les prédictions de Full(opt), nous avons calculé des scores d'importance à partir d'une forêt aléatoire entraînée sur le jeu complet, avec regroupement des caractéristiques par branche source. La Figure 13 montre la contribution relative de chaque famille.




Figure 13 – Importance des caractéristiques par branche (forêt aléatoire sur Full(opt)). Le HOG et le LBP contribuent le plus ; les statistiques et la DWT apportent des gains complémentaires plus modestes.

Le HOG domine en raison de sa haute dimensionnalité et de sa forte discriminabilité basée sur les gradients. Le LBP apporte une information texturale complémentaire. Les statistiques et la DWT fournissent des gains plus faibles mais non nuls, en cohérence avec l'amélioration observée du HOG seul (90,3 %) au Full(opt) (92,0 %).

Visualisation de l'espace des caractéristiques

La Figure 14 présente une projection t-SNE 2D des vecteurs Full(opt) à 526 dimensions pour tous les échantillons de test.




Figure 14 – Visualisation t-SNE des caractéristiques Full(opt) (partition de test). Une séparation partielle des classes est visible ; les clusters gliome et méningiome se chevauchent davantage que l’hypophysaire, ce qui explique la confusion résiduelle du meilleur modèle.

La tumeur hypophysaire forme un cluster bien séparé, ce qui explique la forte précision par classe pour cette catégorie. Le chevauchement partiel entre gliome et méningiome correspond à la principale zone de confusion dans les résultats de classification.

Validation statistique

Validation croisée

Une validation croisée à 5 plis a été réalisée sur l’ensemble d’entraînement pour le meilleur pipeline (Full(opt) + SVM) :

Table 6 – Résultats de la validation croisée à 5 plis pour Full(opt) + SVM.

Métrique	Moyenne	Écart-type
F1-macro	0.8951	0.0100
Précision	0.8953	0.0099

Le faible écart-type confirme une performance stable entre les plis, ce qui soutient la généralisation au-delà de la partition train/test spécifique.

Stabilité par graine aléatoire

Pour vérifier que les résultats ne dépendent pas uniquement de la graine 42, nous avons répété le pipeline complet (re-partitionnement des données, ré-ajustement des hyperparamètres) pour les graines 43 et 44. Le Tableau 7 rapporte les résultats.

Table 7 – Stabilité par graine : Full(opt) + SVM relancé sur trois partitions indépendantes.

Graine	Précision	F1-macro
42	0.9500	0.9498
43	0.9100	0.9099
44	0.9133	0.9130
Moyenne $\pm$ IC 95 %	—	0.9242 $\pm$ 0.0251

Les performances varient d'environ $\pm 0,02$ selon la graine, indiquant une robustesse au partitionnement des données. Cette variation provient des frontières de classe différentes entre partitions.

Intervalles de confiance bootstrap

À partir de $N = 2000$ rééchantillonnages bootstrap de l'ensemble de test tenu à l'écart, nous avons estimé des intervalles de confiance à 95 % pour le meilleur pipeline (Tableau 8).

Table 8 – Intervalles de confiance bootstrap à 95 % pour Full(opt) + SVM (test tenu à l'écart).

Métrique	Estimation ponctuelle	IC 95 %
F1-macro	0.9204	[0.8895, 0.9504]
Précision	92.0%	[0.8900, 0.9500]

La Figure 15 montre la distribution bootstrap pour le meilleur jeu de caractéristiques.




Figure 15 — Distribution bootstrap du F1-macro pour Full(opt) + SVM (2000 ré-échantillonnages). L'IC à 95 % est indiqué par des lignes verticales en pointillés.

Tests de significativité

9.4.1 Test de McNemar (comparaison par paires sur Full(opt))

Le test de McNemar compare les schémas d'erreur de deux classifieurs sur le même ensemble de test. Le Tableau 9 résume les comparaisons significatives avec le SVM.

Table 9 — Test de McNemar : SVM contre d'autres classifieurs sur Full(opt). Significatif à $p < 0,05$.

Modèle A	Modèle B	p -valeur	Significatif ?
SVM	Random Forest	0.0056	Oui
SVM	XGBoost	0.019	Oui
SVM	KNN	0.39	Non

Le SVM est significativement meilleur que les ensembles d'arbres, mais pas significativement meilleur que le KNN — en cohérence avec le classement où les deux figurent parmi les meilleures configurations.

9.4.2 Test de Friedman

Un test de Friedman sur tous les classifieurs au sein du jeu Full(opt) a donné une statistique χ^2 correspondant à $p = 0.0013$, confirmant que le choix du classifieur a un effet statistiquement significatif sur les performances pour ce jeu de caractéristiques.

La Figure 16 fournit une synthèse visuelle des résultats de validation.




Figure 16 — Synthèse de la validation statistique : IC bootstrap, résultats des plis de validation croisée et tests de significativité pour la meilleure configuration.

Discussion

Pourquoi l'optimisation des caractéristiques aide

La recherche de séparabilité en Phase 1 sélectionne les paramètres de descripteurs qui maximisent l'information discriminante entre classes avant tout entraînement de classifieur. Cela évite un essai-erreur coûteux en Phase 2 et garantit que les caractéristiques entrant dans le benchmark sont déjà bien réglées. Le gain de 1.7 points de pourcentage du HOG seul au Full(opt) — modeste en valeur absolue — est statistiquement significatif (McNemar vs. RF : $p = 0.0056$) et suggère que les quatre familles de descripteurs complémentaires capturent une information non redondante.

Pourquoi le SVM performe le mieux

Le SVM à noyau polynomial capture des frontières de classe non linéaires dans l'espace Full(opt) à 526 dimensions. Les descripteurs denses en haute dimension (le HOG contribue à la majorité des 526 dimensions) favorisent généralement les apprenants à marge plutôt que les stratégies de bagging ou de boosting sur des jeux de données de taille modeste. Le fait que le KNN figure également en tête du classement suggère que l'espace Full(opt) possède une géométrie locale forte près des frontières de décision.

Limites

- Le jeu de données (1 500 images) reste modeste ; les résultats peuvent ne pas se généraliser à des populations multi-scanners ou multi-centres.
- Le pipeline de prétraitement (CLAHE, redimensionnement fixe) n'est pas adapté aux protocoles d'acquisition spécifiques.
- Les modèles d'apprentissage profond dépassent souvent le ML classique sur de grands jeux IRM ; notre pipeline cible le scénario de données limitées et de contraintes d'interprétabilité.

Implications pratiques

Le pipeline s'exécute entièrement sur CPU, sans outillage propriétaire, et produit des descripteurs dont la signification physique (texture, fréquence, contours) est compréhensible par les experts du domaine. Il est donc adapté comme outil d'aide à la décision dans des contextes où les ressources de calcul ou les volumes de données excluent l'apprentissage profond.

Conclusion et perspectives

Synthèse

Ce rapport a présenté un pipeline ML en deux phases pour la classification IRM de tumeurs cérébrales. La Phase 1 a utilisé trois métriques de séparabilité (FDR, MI, DBI) pour sélectionner les paramètres optimaux de quatre familles de descripteurs artisanaux sur 213 configurations, sans entraînement de classifieur. La Phase 2 a benchmarké 8 classifieurs sur 8 jeux de caractéristiques (64 pipelines évalués), avec une validation statistique complète.

Les principaux résultats sont les suivants :

- **Meilleur pipeline** : Full(opt) + SVM — précision 92.0%, F1-macro 0.9204, $\kappa = 0.880$.
- **La fusion améliore les familles isolées** : + 1.7 points de pourcentage par rapport à la référence HOG seul.
- **Robustesse statistique** : variance CV $\leq 0,01$, IC bootstrap [0.8895, 0.9504], F1 moyen par graine 0.9242.
- **Significativité du SVM** : significativement meilleur que RF et XGBoost sur Full(opt) (McNemar, $p < 0,02$).

Perspectives

1. **Comparaison avec l'apprentissage profond** : évaluer des CNN (EfficientNet, ResNet) et des Vision Transformers sur le même jeu de données et protocole pour une comparaison directe.
2. **Systèmes hybrides ML/DL** : combiner des caractéristiques artisanaux optimisées avec des embeddings appris en profondeur pour un pool de caractéristiques complémentaire.
3. **IA explicable** : intégrer Grad-CAM ou SHAP pour fournir des explications spatiales aux côtés de la décision du classifieur, renforçant la confiance clinique.
4. **Validation multi-centres** : évaluer le pipeline sur des jeux de données hétérogènes en termes d'appareils pour mesurer la généralisabilité clinique.

L'apprentissage automatique classique avec des descripteurs artisanaux optimisés reste une approche compétitive et transparente pour la classification IRM de tumeurs cérébrales, en particulier dans des scénarios à données limitées et à forte exigence d'interprétabilité.

Références

- [1] U. BHIMAVARAPU, N. CHINTALAPUDI et G. BATTINENI, « Brain Tumor Detection and Categorization with Segmentation of Improved Unsupervised Clustering Approach and Machine Learning Classifier, » *Bioengineering*, t. 11, n° 3, p. 266, 2024. DOI : [10.3390/bioengineering11030266](https://doi.org/10.3390/bioengineering11030266)
- [2] M. OTTONI, A. KASPERCZUK et L. M. N. TAVORA, « Machine Learning in MRI Brain Imaging : A Review of Methods, Challenges, and Future Directions, » *Diagnostics*, t. 15, n° 21, p. 2692, 2025. DOI : [10.3390/diagnostics15212692](https://doi.org/10.3390/diagnostics15212692)