


CLASSIFICATION DES IMAGE PAR MACHINE LEARNING

*Brain Tumor MRI Classification Using
Traditional Machine Learning*

Module Projet 1



Année universitaire :
2025–2026

Encadré par : *Pr. Ilham El Ouariachi*

Réaliser par : *Ferrah Othmane
Zerrouh Taleb
Ahmed Daouiou*

Table des matières

Introduction Générale	4
1 Contexte	4
2 Problématique	4
3 Objectifs du projet	4
4 Contributions	4
1 État de l'art	6
1 Introduction	6
2 Machine Learning traditionnel	6
2.1 Support Vector Machine (SVM)	6
2.2 K-Nearest Neighbors (KNN)	7
2.3 Random Forest	7
2.4 Extra Trees	7
2.5 Régression Logistique	7
3 Deep Learning pour l'imagerie médicale	7
3.1 Convolutional Neural Networks (CNN)	7
3.2 VGG	8
3.3 ResNet	8
3.4 Architectures récentes : EfficientNet et Vision Transformers	8
4 Handcrafted Features vs Deep Features	8
4.1 Familles de caractéristiques manuelles	8
4.2 Avantages des caractéristiques manuelles	9
4.3 Limites des caractéristiques manuelles	9
4.4 Pourquoi les étudier encore aujourd'hui ?	9
5 Synthèse des travaux récents sur la classification des tumeurs cérébrales	9
5.1 Approches basées sur la fusion de caractéristiques manuelles	10
5.2 Analyse critique de l'état de l'art	11
2 Jeu de données et prétraitement	12
1 Présentation du dataset	12
1.1 Source du dataset	12
1.2 Composition du dataset	12
1.3 Description des classes	12
2 Répartition des données d'apprentissage et de test	13
3 Prétraitement des images	13
3.1 Conversion en niveaux de gris	14
3.2 Redimensionnement des images	14
3.3 Normalisation des intensités	14
3.4 Amélioration du contraste par CLAHE	14
3.5 Pipeline complet de prétraitement	14

3	Extraction des caractéristiques	16
1	Vue d'ensemble	16
2	Histogram of Oriented Gradients (HOG)	16
2.1	Principe	17
2.2	Hyperparamètres étudiés	17
3	Caractéristiques statistiques (A)	17
4	Gray Level Co-occurrence Matrix (GLCM)	18
4.1	Principe	18
4.2	Hyperparamètres étudiés	18
4.3	Caractéristiques extraites	19
5	Local Binary Patterns (LBP)	20
5.1	Principe	20
5.2	Hyperparamètres étudiés	20
6	Discrete Wavelet Transform (DWT)	20
6.1	Principe	20
6.2	Familles d'ondelettes	21
6.3	Niveaux de décomposition	21
7	Synthèse des dimensions par groupe de caractéristiques	21
4	Optimisation des descripteurs (Phase 1)	22
1	Motivation	22
2	Métriques de séparabilité	22
2.1	Fisher Discriminant Ratio (FDR)	22
2.2	Mutual Information (MI)	23
2.3	Davies–Bouldin Index (DBI)	23
3	Construction du score composite	23
4	Recherche des meilleurs paramètres	24
4.1	Optimisation du descripteur GLCM	24
4.2	Optimisation du descripteur LBP	24
4.3	Optimisation du descripteur DWT	25
4.4	Optimisation du descripteur HOG	25
5	Synthèse de la Phase 1	25
5	Construction des ensembles de caractéristiques (Phase 2)	27
1	Construction des ensembles de caractéristiques	27
1.1	Ensemble A : Caractéristiques statistiques	27
1.2	Ensemble B : Texture (GLCM + LBP)	28
1.3	Ensemble C : DWT	28
1.4	Ensemble D : HOG	28
1.5	Ensembles fusionnés	28
2	Nettoyage et préparation des caractéristiques	28
2.1	Suppression des caractéristiques à faible variance	29
2.2	Élimination des caractéristiques fortement corrélées	29
2.3	Standardisation des caractéristiques	29
3	Réduction de la redondance et analyse des dimensions	29
3.1	Synthèse de la Phase 2	30
6	Benchmark des modèles de Machine Learning	33
1	Modèles évalués	33
1.1	Support Vector Machine (SVM)	33
1.2	K-Nearest Neighbors (KNN)	33
1.3	Random Forest (RF)	33
1.4	Extra Trees (ET)	33
1.5	Logistic Regression (LR)	33

1.6	Multi-Layer Perceptron (MLP)	34
1.7	XGBoost	34
1.8	LightGBM	34
2	Stratégie d'évaluation	34
2.1	Optimisation des hyperparamètres par GridSearchCV	34
2.2	Validation croisée stratifiée	34
2.3	Métrique d'évaluation : F1-Macro	35
3	Résultats détaillés	35
4	Leaderboard global	35
7	Validation statistique	41
1	Coefficient de Cohen's Kappa	41
2	Intervalle de confiance Bootstrap	41
3	Analyse par validation croisée	42
3.1	Moyenne des performances	43
3.2	Écart-type des performances	43
4	Test de McNemar	43
5	Test de Wilcoxon	44
6	Tests de Friedman et Nemenyi	44
7	Synthèse statistique	44
8	Analyse et discussion	46
1	Analyse des performances	46
2	Contribution des branches de caractéristiques	46
3	Effet de la fusion	46
4	Comparaison avec la littérature	47
5	Limites et perspectives	47
9	Extensions exploratoires : Deep Learning et VLM	48
1	Benchmark Deep Learning (Deep_learning.ipynb)	48
1.1	Protocole	48
1.2	Résultats principaux	48
2	Exploration VLM (VLM.ipynb)	51
2.1	Objectif et architecture	51
2.2	Teacher Forcing et sondes de probabilité	51
2.3	Résultats	51
3	Synthèse	54
	Conclusion Générale	55
	Bibliographie	57

Introduction Générale

1 Contexte

L’Imagerie par Résonance Magnétique (IRM) est un outil incontournable pour l’analyse des pathologies cérébrales. Les tumeurs cérébrales constituent toutefois un défi diagnostique majeur : plusieurs types présentent des apparences visuelles proches, et leur interprétation requiert une expertise médicale approfondie.

L’Intelligence Artificielle offre des perspectives prometteuses pour automatiser cette analyse. Si le Deep Learning domine la littérature récente, les approches fondées sur des caractéristiques manuelles (*handcrafted features*) conservent un intérêt fort grâce à leur interprétabilité, leur faible coût computationnel et leur robustesse sur des jeux de données de taille modérée.

2 Problématique

La classification automatique des tumeurs cérébrales repose sur la qualité des descripteurs utilisés pour représenter les images. Statistiques d’intensité, textures (GLCM, LBP), informations fréquentielles (DWT) et contours (HOG) capturent chacun un aspect différent de l’image ; leur combinaison et leur optimisation conditionnent directement les performances des modèles de Machine Learning.

Ce projet adopte donc une stratégie d’ingénierie des caractéristiques : extraire, optimiser, fusionner et évaluer systématiquement plusieurs familles de descripteurs avant de comparer les algorithmes de classification.

3 Objectifs du projet

L’objectif principal est de développer un système complet de classification multiclassées des tumeurs cérébrales à partir d’images IRM. Les objectifs spécifiques sont :

- concevoir un pipeline de bout en bout (prétraitement, extraction, classification) ;
- optimiser les paramètres des descripteurs GLCM, LBP, DWT et HOG ;
- construire et comparer huit ensembles de caractéristiques fusionnés ;
- benchmarker huit modèles de Machine Learning et identifier la meilleure configuration ;
- valider statistiquement la robustesse des résultats obtenus.

4 Contributions

Ce travail apporte :

- une optimisation systématique des descripteurs en Phase 1 (score de séparabilité) ;
- une fusion multi-branches avec nettoyage des redondances (Phase 2) ;
- un benchmark comparatif de 64 expériences (8 modèles $\times$ 8 ensembles) ;
- une validation statistique complète (Kappa, Bootstrap, McNemar, Friedman) ;
- une analyse d’interprétabilité par importance des branches de caractéristiques.

Le Chapitre 1 présente l'état de l'art ; les Chapitres 2 à 5 décrivent le dataset, l'extraction, l'optimisation et la construction des ensembles ; les Chapitres 6 et 7 rapportent le benchmark et la validation statistique ; les Chapitres 8 et 9 analysent les résultats et ouvrent vers le Deep Learning et les modèles Vision-Language.

Chapitre 1

État de l’art

1 Introduction

L’analyse automatique des images médicales constitue aujourd’hui l’un des domaines les plus actifs de la recherche en intelligence artificielle appliquée à la santé. Grâce aux progrès de l’imagerie médicale et à l’augmentation de la quantité de données disponibles, les systèmes d’aide au diagnostic assistés par ordinateur (*Computer-Aided Diagnosis* — CAD) sont devenus des outils prometteurs pour améliorer la précision et la rapidité des décisions cliniques.

Parmi les différentes tâches d’analyse d’images médicales, la classification occupe une place centrale. Elle consiste à attribuer automatiquement une image à une catégorie prédéfinie en fonction des caractéristiques qu’elle contient. Dans le domaine de la neuro-oncologie, cette tâche vise notamment à distinguer différents types de tumeurs cérébrales (gliome, méningiome, tumeur pituitaire, ou absence de tumeur) à partir d’images d’Imagerie par Résonance Magnétique (IRM).

L’IRM est considérée comme la modalité d’imagerie de référence pour l’étude du cerveau grâce à sa capacité à fournir des informations anatomiques détaillées sans exposition aux rayonnements ionisants. Elle permet de visualiser la localisation, la taille et certaines propriétés des tumeurs cérébrales, facilitant ainsi leur diagnostic et leur suivi clinique. Cependant, l’interprétation manuelle des examens IRM demeure une tâche complexe, chronophage et sujette à une variabilité inter- et intra-observateur susceptible d’affecter la reproductibilité du diagnostic.

Afin d’améliorer la fiabilité des diagnostics, de nombreuses méthodes d’intelligence artificielle ont été proposées pour automatiser l’analyse des images médicales. Ces approches reposent principalement sur deux paradigmes : le *Machine Learning* traditionnel, fondé sur l’extraction de caractéristiques explicites suivie d’un classifieur, et le *Deep Learning*, capable d’apprendre automatiquement des représentations à partir des données brutes. Ce chapitre présente les fondements de ces deux familles d’approches, discute l’opposition entre caractéristiques manuelles et caractéristiques profondes, puis dresse une synthèse critique des travaux récents consacrés à la classification des tumeurs cérébrales.

2 Machine Learning traditionnel

Les méthodes de Machine Learning traditionnel reposent généralement sur deux étapes principales : l’extraction de caractéristiques descriptives à partir des images, puis l’apprentissage d’un modèle de classification à partir de ces caractéristiques. Cette approche présente l’avantage de produire des représentations interprétables tout en nécessitant moins de données et de ressources de calcul que les méthodes profondes.

2.1 Support Vector Machine (SVM)

Le Support Vector Machine (SVM) est l’un des algorithmes les plus utilisés en classification d’images médicales. Son principe consiste à rechercher l’hyperplan optimal séparant les différentes classes tout en maximisant la marge entre celles-ci.

Grâce à l'utilisation de fonctions noyaux (*kernels*), le SVM est capable de modéliser des frontières de décision complexes dans des espaces de grande dimension. Il est particulièrement adapté aux jeux de données comportant un nombre limité d'exemples mais un grand nombre de caractéristiques, situation fréquemment rencontrée dans les applications médicales, ce qui explique sa présence récurrente comme classifieur final dans les approches hybrides récentes.

2.2 K-Nearest Neighbors (KNN)

L'algorithme K-Nearest Neighbors (KNN) repose sur un principe simple : un nouvel échantillon est affecté à la classe majoritaire parmi ses k voisins les plus proches dans l'espace des caractéristiques.

Cette méthode ne nécessite pas de phase d'apprentissage complexe et constitue souvent une référence efficace pour les problèmes de classification. Toutefois, ses performances peuvent être dégradées par la présence de caractéristiques redondantes ou par la malédiction de la dimensionnalité, ce qui rend souvent nécessaire une étape de réduction de dimension (par exemple par Analyse en Composantes Principales).

2.3 Random Forest

Random Forest est une méthode d'apprentissage par ensemble basée sur la combinaison de plusieurs arbres de décision construits sur des sous-échantillons aléatoires des données.

La prédiction finale est obtenue par vote majoritaire des arbres individuels. Cette approche permet généralement d'améliorer la robustesse du modèle et de réduire les risques de surapprentissage tout en offrant des mécanismes d'évaluation de l'importance des caractéristiques.

2.4 Extra Trees

L'algorithme Extra Trees (*Extremely Randomized Trees*) constitue une variante de Random Forest introduisant davantage d'aléatoire lors de la construction des arbres.

Contrairement à Random Forest, les seuils de séparation sont sélectionnés de manière aléatoire, ce qui contribue à réduire davantage la variance du modèle et à améliorer sa capacité de généralisation dans certains contextes.

2.5 Régression Logistique

La Régression Logistique (*Logistic Regression*) est une méthode statistique supervisée largement utilisée pour les tâches de classification.

Bien que relativement simple, elle offre une bonne interprétabilité des résultats et constitue souvent une référence de base dans les études comparatives. Son efficacité dépend toutefois de la capacité des caractéristiques à séparer linéairement les différentes classes.

3 Deep Learning pour l'imagerie médicale

L'émergence du Deep Learning a profondément transformé le domaine de l'analyse d'images médicales. Contrairement aux approches traditionnelles, les modèles profonds apprennent automatiquement les représentations pertinentes directement à partir des pixels de l'image, supprimant ainsi l'étape d'ingénierie manuelle des caractéristiques.

Cette capacité à extraire des caractéristiques hiérarchiques a permis d'obtenir des performances remarquables dans de nombreuses applications de détection, segmentation et classification médicale.

3.1 Convolutional Neural Networks (CNN)

Les réseaux de neurones convolutifs (CNN) constituent l'architecture de référence pour le traitement des images.

Les couches convolutives permettent d'extraire automatiquement des motifs visuels tels que les contours, les textures ou les structures complexes présentes dans les images médicales. Les couches

profondes apprennent progressivement des représentations de plus en plus abstraites favorisant la discrimination entre les différentes classes.

3.2 VGG

VGG est une architecture profonde caractérisée par l'utilisation répétée de petites convolutions de taille 3×3 .

Sa simplicité architecturale et ses bonnes performances ont contribué à sa popularité dans les applications médicales. Les versions pré-entraînées sur de grands jeux de données peuvent être adaptées aux tâches médicales grâce à des techniques de transfert d'apprentissage. Plusieurs travaux rapportent des précisions supérieures à 98 % avec des variantes VGG-16 et VGG-19 en classification binaire de tumeurs cérébrales.

3.3 ResNet

ResNet (*Residual Network*) introduit le concept de connexions résiduelles permettant de faciliter l'apprentissage de réseaux très profonds.

Cette innovation réduit les problèmes de disparition du gradient et améliore significativement les performances sur les tâches complexes de classification. Les architectures ResNet figurent aujourd'hui parmi les modèles les plus utilisés dans les travaux récents portant sur la classification des tumeurs cérébrales, souvent comme extracteur de caractéristiques au sein d'approches hybrides ou de transfert d'apprentissage.

3.4 Architectures récentes : EfficientNet et Vision Transformers

Au-delà des architectures classiques, les travaux les plus récents s'appuient sur des modèles plus efficaces ou plus expressifs. EfficientNet propose un équilibrage systématique de la profondeur, de la largeur et de la résolution du réseau, permettant d'atteindre de hautes performances avec un nombre réduit de paramètres. Parallèlement, les Vision Transformers (ViT) et leurs variantes hiérarchiques telles que le Swin Transformer exploitent des mécanismes d'attention pour capturer des dépendances à longue portée dans l'image, et atteignent actuellement les meilleures performances rapportées sur les jeux de données de référence.

4 Handcrafted Features vs Deep Features

Les approches traditionnelles et profondes présentent chacune des avantages et des limitations. Le choix entre ces deux paradigmes dépend généralement du volume de données disponible, des ressources de calcul et des objectifs d'interprétabilité.

4.1 Familles de caractéristiques manuelles

Les caractéristiques conçues manuellement (*Handcrafted Features*) sont traditionnellement regroupées en trois catégories complémentaires :

- les caractéristiques **d'intensité**, qui décrivent la distribution locale des niveaux de gris (moyenne, écart-type, asymétrie, aplatissement, mesures histogrammiques) ;
- les caractéristiques de **texture**, qui décrivent l'arrangement spatial des intensités : matrices de cooccurrence (GLCM), motifs binaires locaux (LBP), filtres de Gabor et transformées en ondelettes (DWT) ;
- les caractéristiques de **forme**, qui capturent les propriétés géométriques de la région tumorale (aire, périmètre, compacité, moments), auxquelles s'ajoutent les histogrammes de gradients orientés (HOG) décrivant les contours.

Dans ce projet, cinq familles de descripteurs sont étudiées : Statistiques, GLCM, LBP, DWT et HOG.

4.2 Avantages des caractéristiques manuelles

Les caractéristiques manuelles offrent plusieurs avantages :

- forte interprétabilité des informations extraites ;
- besoins réduits en données d’entraînement ;
- coût computationnel relativement faible ;
- facilité d’analyse et de validation scientifique ;
- compatibilité avec de nombreux algorithmes de Machine Learning.

4.3 Limites des caractéristiques manuelles

Malgré leurs avantages, les caractéristiques manuelles présentent certaines limites. Leur qualité dépend fortement de l’expertise du concepteur et des choix effectués lors de l’extraction. Elles peuvent également être moins capables de capturer des représentations complexes ou de haut niveau présentes dans les données médicales.

Par ailleurs, aucun descripteur unique n’est généralement suffisant pour représenter l’ensemble des informations pertinentes contenues dans une image IRM. Cette limitation motive les stratégies de *fusion* de descripteurs étudiées dans ce travail. À titre d’illustration, une étude comparative sur un jeu T1 de 2870 IRM montre qu’un descripteur isolé plafonne autour de 85 % de précision (HOG avec un KNN de type *subspace*), tandis que la fusion GLCM + HOG + LBP porte la précision à 91,1 % avec un classifieur *fine* KNN [1]. Ce gain confirme la complémentarité des descripteurs de texture et de forme.

4.4 Pourquoi les étudier encore aujourd’hui ?

Malgré la domination actuelle du Deep Learning, les approches basées sur les caractéristiques manuelles conservent un intérêt scientifique et pratique important. Elles demeurent particulièrement pertinentes lorsque les ressources de calcul sont limitées ou lorsque la quantité de données disponibles est insuffisante pour entraîner efficacement des réseaux profonds.

De plus, l’interprétabilité constitue aujourd’hui un enjeu majeur dans les applications médicales. Les caractéristiques manuelles permettent de comprendre plus facilement les éléments utilisés par les modèles pour prendre leurs décisions, ce qui favorise leur acceptation dans les environnements cliniques. Enfin, elles ne s’opposent pas nécessairement aux approches profondes : de nombreux travaux récents fusionnent descripteurs profonds et descripteurs manuels (par exemple CNN + GLCM ou CNN + HOG) afin de combiner sémantique de haut niveau et sensibilité aux textures fines.

Dans ce contexte, ce projet s’inscrit dans la continuité de ces travaux en étudiant l’impact de plusieurs familles de descripteurs manuels sur la classification multiclasse des tumeurs cérébrales à partir d’images IRM, tout en évaluant leur complémentarité à travers différentes stratégies de fusion et plusieurs algorithmes de Machine Learning.

5 Synthèse des travaux récents sur la classification des tumeurs cérébrales

Au cours des dernières années, de nombreux travaux ont exploré l’utilisation des techniques de Machine Learning et de Deep Learning pour la classification automatique des tumeurs cérébrales à partir d’images IRM. Les performances rapportées dans la littérature ont connu une progression importante grâce à l’utilisation de réseaux convolutifs profonds, de stratégies de transfert d’apprentissage, ainsi que d’approches hybrides combinant extraction de caractéristiques et modèles de classification.

Le Tableau 1.1 présente une synthèse de plusieurs travaux récents représentatifs de l’état de l’art. Les méthodes recensées couvrent aussi bien les approches traditionnelles basées sur des caractéristiques manuelles que les architectures profondes modernes utilisant le transfert d’apprentissage ou la fusion de caractéristiques.

L'analyse de ces résultats montre que les architectures de Deep Learning atteignent généralement des performances supérieures à 98 % de précision sur les jeux de données les plus utilisés. Toutefois, ces performances reposent souvent sur des modèles complexes nécessitant des ressources computationnelles importantes, des techniques d'augmentation de données avancées et parfois des architectures hybrides difficiles à interpréter.

À l'inverse, les approches fondées sur des caractéristiques manuelles conservent plusieurs avantages importants, notamment leur interprétabilité, leur faible coût de calcul et leur capacité à fonctionner efficacement sur des ensembles de données de taille limitée. Cette observation justifie l'intérêt de poursuivre l'étude des descripteurs classiques et de leurs combinaisons dans un contexte médical où la transparence des décisions constitue un critère essentiel.

Le présent projet s'inscrit dans cette perspective en proposant une étude approfondie de plusieurs familles de caractéristiques manuelles (Statistiques, GLCM, LBP, DWT et HOG), associées à un benchmark exhaustif de huit algorithmes de Machine Learning et à une validation statistique rigoureuse des résultats obtenus.

TABLE 1.1 – Comparaison de travaux récents sur la classification des tumeurs cérébrales à partir d'images IRM.

Réf.	Méthode	Dataset	Cl.	Acc.	Prec.	Rec.	F1
Afzal et al. [2]	ResNet18 + Transfer Learning + CART-ANOVA	Kaggle + Radiopaedia	4	99.7	–	–	99.7
Ullah et al. [3]	VGG-16 / VGG-19 Transfer Learning	Brain Tumor MRI (Kaggle)	2	99.2	99.0	99.0	99.0
Ullah et al. [4]	InceptionResNetV2 (Transfer Learning)	Glioma / Mening. / Pituit.	3	98.9	98.3	99.8	99.0
Younis et al. [5]	VGG-16 Fine-Tuning	T1 MRI (253 images)	2	98.5	–	94.5	92.6
Shah et al. [6]	EfficientNet-B0 (Fine-Tuning)	Kaggle + BraTS2015 / TCIA	2	98.9	98.9	98.8	98.8
Kundari et al. [7]	DCNN + LBP/ICA + SVM	Glioma / Mening. / Pituit.	3	99.0	–	97.3	–
Badža et al. [8]	CNN personnalisé (22 couches)	Figshare MRI Dataset	3	96.6	–	–	97.5
Zahoor et al. [9]	BRAIN-RENet + HOG + SVM (HFF-BTC)	MRI Dataset	3	99.2	–	–	99.1
Dixon et al. [10]	CNN + ViT + Radiomics (GLCM/LBP) + MLP	Public + Local	4	99.4	–	99.5	–
Pacal et al. [11]	Swin Transformer + MLP résiduel	MRI Dataset	4	99.9	99.9	99.8	99.9

Cl. = nombre de classes ; métriques en % (Accuracy, Precision, Recall, F1).

Note méthodologique :

Les valeurs reportées correspondent aux meilleures configurations décrites par les auteurs. Certaines entrées sont issues d'une revue systématique récente [12], où les protocoles d'évaluation (découpage des données, augmentation, validation croisée) ne sont pas toujours homogènes. Les comparaisons directes entre lignes doivent donc être interprétées avec prudence (voir Section 5.2).

5.1 Approches basées sur la fusion de caractéristiques manuelles

Plusieurs travaux confirment spécifiquement l'apport de la fusion de descripteurs classiques, qui constitue le cœur de notre étude. Sur un jeu T1 de 2870 IRM à quatre classes, la combinaison GLCM + HOG + LBP atteint 91,1 % de précision (fine KNN), contre au plus 85 % pour un descripteur isolé, démontrant la complémentarité texture/forme [1]. D'autres études rapportent des combinaisons LBP + HOG associées à une réduction de dimension par ACP et un classifieur SVM, ou encore l'ajout de *features* d'interaction obtenues par produit externe des vecteurs GLCM et LBP, atteignant des précisions de l'ordre de 96 % en classification multiclassées [13, 12]. Ces résultats situent les approches purement manuelles dans une gamme de 85 à 96 %, inférieure aux modèles profonds les plus

récents, mais obtenue avec des modèles nettement plus légers, plus rapides à entraîner et plus faciles à interpréter.

Le Tableau 1.2 synthétise plusieurs travaux récents fondés exclusivement sur des caractéristiques manuelles et des classifieurs classiques.

TABLE 1.2 – Travaux récents utilisant le Machine Learning traditionnel (caractéristiques manuelles et classifieurs classiques) pour la classification des tumeurs cérébrales à partir d’images IRM.

Réf.	Méthode (descripteurs + classifieur)	Dataset	Cl.	Acc.	Prec.	Rec.	F1
Kumar et al. [14]	Random Forest + Image Loading / HOG / LBP	Kaggle (2 datasets)	2	99.0	99.0	97.0	98.0
Muthaiyan & Malleswaran [15]	Bendlets (BCF, HPBC, HNBC) + Ensemble (kNN / NB / SVM)	REMBRANDT	2	99.5	–	99.0	–
Basthikodi et al. [13]	SVM + HOG + LBP + PCA	Kaggle (7023 img.)	4	96.0	96.0	96.0	96.0
Pattanaik et al. [1]	Fine KNN + fusion GLCM + HOG + LBP	Figshare (2870 img.)	4	91.1	–	–	–

Cl. = nombre de classes ; métriques en % (Accuracy, Precision, Recall, F1).

Note :

Pattanaik et al. rapportent une AUC de 0.96 pour la meilleure configuration (fusion GLCM+HOG+LBP, *fine* KNN) ; la précision d’un descripteur isolé y plafonne à 85 % (HOG, *sub-space* KNN). Muthaiyan & Malleswaran opèrent en deux étapes (normal/anormal puis faible/haut risque) : 99.5 % et 99 % respectivement. Kumar et al. obtiennent 99 % avec Random Forest et le chargement d’image, SVM et régression logistique se situant entre 97 et 99 %.

5.2 Analyse critique de l’état de l’art

L’analyse des travaux récents met en évidence plusieurs tendances majeures.

Premièrement, les modèles de Deep Learning dominent actuellement la littérature grâce à leur capacité à apprendre automatiquement des représentations complexes à partir des images IRM. Les architectures fondées sur le transfert d’apprentissage (ResNet, VGG, EfficientNet, InceptionResNet) et, plus récemment, les Transformers hiérarchiques (Swin) atteignent régulièrement des taux de classification supérieurs à 99 %.

Deuxièmement, les approches hybrides associant réseaux profonds et classificateurs traditionnels, ou fusionnant caractéristiques profondes et manuelles, égalent ou surpassent souvent les modèles purement neuronaux. Les travaux combinant CNN + SVM, BRAIN-RENet + HOG + SVM ou encore CNN + ViT + radiomique montrent que les informations extraites à différents niveaux sont complémentaires.

Troisièmement, la majorité des études se concentrent sur l’amélioration des performances prédictives, tandis que peu abordent en profondeur l’interprétabilité et la validation statistique des résultats. Dans un contexte médical, cette limitation constitue un obstacle important à l’adoption clinique.

Enfin, et surtout, les performances très élevées rapportées (souvent supérieures à 99 %) doivent être interprétées avec prudence. Une revue récente souligne notamment qu’une précision de 100 % a été obtenue par un CNN entraîné sur seulement 253 images IRM augmentées, illustrant comment des jeux de données de très petite taille peuvent gonfler artificiellement les estimations de performance [12]. À cela s’ajoutent l’hétérogénéité des protocoles d’évaluation, les fuites potentielles entre patients lors des découpages image-par-image, et le manque de standardisation des jeux de données, qui limitent la comparabilité directe des résultats et leur généralisation aux données cliniques réelles.

C’est dans cette optique que s’inscrit notre travail, qui vise à étudier systématiquement l’apport de plusieurs familles de descripteurs manuels, leur complémentarité et leur impact sur différents algorithmes de Machine Learning, à travers une méthodologie rigoureuse de benchmarking et de validation statistique, privilégiant la transparence et la reproductibilité plutôt que la seule maximisation de la précision.

Chapitre 2

Jeu de données et prétraitement

1 Présentation du dataset

1.1 Source du dataset

Dans le cadre de ce projet, nous avons utilisé un jeu de données d’images d’Imagerie par Résonance Magnétique (IRM) cérébrale destiné à la classification multiclassées des tumeurs cérébrales. Ce dataset est largement utilisé dans la littérature scientifique pour l’évaluation des algorithmes de classification médicale et contient des images représentant différents types de tumeurs cérébrales.

Les images sont issues d’examens IRM réalisés sur des patients présentant diverses pathologies tumorales. Chaque image est associée à une étiquette indiquant la catégorie de tumeur correspondante, permettant ainsi l’utilisation de méthodes d’apprentissage supervisé.

1.2 Composition du dataset

Afin de garantir un apprentissage équilibré et d’éviter les biais liés au déséquilibre des classes, un sous-ensemble équilibré de 1,500 images a été constitué. Le jeu de données est réparti équitablement entre trois catégories de tumeurs cérébrales.

TABLE 2.1 – Répartition des images par classe.

Classe	Nombre d’images
Glioma	500
Meningioma	500
Pituitary Tumor	500
Total	1,500

Cette répartition équilibrée permet d’assurer une évaluation plus fiable des performances des modèles de classification en évitant qu’une classe ne domine le processus d’apprentissage.

1.3 Description des classes

Les trois catégories étudiées correspondent aux types de tumeurs cérébrales les plus fréquemment rencontrés dans les jeux de données publics d’IRM :

- **Glioma** : tumeur développée à partir des cellules gliales du cerveau. Elle représente l’une des formes les plus courantes de tumeurs cérébrales primaires.
- **Meningioma** : tumeur provenant des méninges, les membranes entourant le cerveau et la moelle épinière. Elle est généralement bénigne mais peut entraîner des complications selon sa localisation.
- **Pituitary Tumor** : tumeur affectant l’hypophyse, une glande endocrine située à la base du cerveau. Son diagnostic précoce est essentiel afin de prévenir les perturbations hormonales associées.

L'objectif du projet consiste à identifier automatiquement la catégorie à laquelle appartient chaque image IRM à partir des caractéristiques visuelles extraites.




FIGURE 2.1 – Vue d'ensemble du dataset : répartition train/test par classe et échantillons visuels des trois catégories de tumeurs.

2 Répartition des données d'apprentissage et de test

Afin d'évaluer correctement la capacité de généralisation des modèles, le jeu de données a été divisé en deux sous-ensembles distincts : un ensemble d'apprentissage destiné à l'entraînement des modèles et un ensemble de test réservé à l'évaluation finale.

Une stratégie de division stratifiée (*Stratified Train-Test Split*) a été adoptée afin de préserver la proportion de chaque classe dans les deux sous-ensembles.

La répartition retenue est de :

- **80 % pour l'apprentissage ;**
- **20 % pour le test.**

Cette configuration conduit à la distribution présentée dans le Tableau 2.2.

TABLE 2.2 – Répartition Train/Test.

Ensemble	Nombre d'images	Pourcentage
Train	1,200	80 %
Test	300	20 %
Total	1,500	100 %

Grâce à cette stratégie, chaque classe reste représentée de manière équilibrée dans les ensembles d'apprentissage et de test, garantissant ainsi une évaluation impartiale des performances.

3 Prétraitement des images

Avant l'extraction des caractéristiques, plusieurs opérations de prétraitement ont été appliquées afin d'améliorer la qualité des images et d'homogénéiser les données. Ces étapes visent à réduire les variations non pertinentes et à faciliter l'extraction de descripteurs robustes.

3.1 Conversion en niveaux de gris

Les images IRM utilisées dans cette étude sont converties en niveaux de gris afin de simplifier leur représentation tout en conservant les informations anatomiques essentielles.

Cette transformation permet de réduire la dimension des données et d'uniformiser les traitements ultérieurs. Elle est particulièrement adaptée aux images médicales IRM où les informations diagnostiques sont principalement contenues dans les variations d'intensité plutôt que dans les composantes colorimétriques.

3.2 Redimensionnement des images

Afin de garantir une représentation uniforme des données, toutes les images sont redimensionnées vers une résolution fixe avant l'extraction des caractéristiques.

Cette étape permet :

- d'assurer la cohérence des dimensions entre les échantillons ;
- de faciliter l'extraction des descripteurs ;
- de réduire le coût computationnel des traitements.

Le redimensionnement garantit également que les caractéristiques extraites soient comparables entre toutes les images du dataset.

3.3 Normalisation des intensités

Les images IRM peuvent présenter des variations importantes d'intensité liées aux conditions d'acquisition ou aux différences entre appareils médicaux.

Une étape de normalisation est donc appliquée afin de ramener les niveaux de gris dans une plage commune de valeurs. Cette opération contribue à réduire l'influence des variations d'éclairage et améliore la robustesse des caractéristiques extraites.

La normalisation facilite également l'apprentissage des modèles en garantissant une échelle homogène des données.

3.4 Amélioration du contraste par CLAHE

Afin de renforcer la visibilité des structures anatomiques et des régions tumorales, une méthode d'amélioration locale du contraste appelée **Contrast Limited Adaptive Histogram Equalization** (CLAHE) est appliquée.

Contrairement à l'égalisation d'histogramme classique, CLAHE agit localement sur différentes régions de l'image tout en limitant l'amplification du bruit.

Cette technique présente plusieurs avantages :

- amélioration du contraste local ;
- meilleure mise en évidence des textures ;
- renforcement des contours et structures tumorales ;
- amélioration de la qualité des caractéristiques extraites.

L'application de CLAHE s'avère particulièrement bénéfique pour les descripteurs de texture tels que GLCM et LBP, qui reposent fortement sur les variations locales d'intensité.

3.5 Pipeline complet de prétraitement

L'ensemble des opérations réalisées avant l'extraction des caractéristiques est résumé dans la Figure 2.2.

Pipeline de prétraitement :

Image IRM originale → Conversion en niveaux de gris → Redimensionnement → Normalisation des intensités → Amélioration du contraste (CLAHE) → Extraction des caractéristiques (Statistiques, GLCM, LBP, DWT, HOG).




FIGURE 2.2 – Pipeline complet de prétraitement des images IRM avant extraction des caractéristiques.

Ce pipeline permet d'obtenir des images homogènes et de meilleure qualité, favorisant ainsi l'extraction de caractéristiques discriminantes et l'amélioration des performances de classification.

Chapitre 3

Extraction des caractéristiques

1 Vue d'ensemble

L'efficacité d'un système de classification d'images médicales dépend fortement de la qualité des caractéristiques utilisées pour représenter les informations visuelles contenues dans les images. Dans le contexte de la classification des tumeurs cérébrales à partir d'images IRM, une représentation pertinente doit être capable de capturer différents aspects de l'image tels que l'intensité des pixels, la texture, les variations fréquentielles ainsi que les structures morphologiques.

Afin d'obtenir une représentation riche et complémentaire des images, ce projet adopte une approche multi-descripteurs basée sur l'extraction de plusieurs familles de caractéristiques manuelles (*Handcrafted Features*). Chaque famille permet de décrire une propriété spécifique de l'image :

- les caractéristiques statistiques décrivent la distribution globale des niveaux de gris ;
- les descripteurs de texture (GLCM et LBP) capturent l'organisation spatiale des pixels ;
- les caractéristiques fréquentielles extraites par DWT analysent les variations à différentes échelles ;
- les descripteurs HOG représentent les contours et les orientations dominantes des gradients.

Cette diversité permet d'exploiter simultanément plusieurs sources d'information et d'étudier leur complémentarité dans le processus de classification.

La Figure 3.1 illustre l'architecture générale de l'extraction des caractéristiques utilisée dans ce travail.




FIGURE 3.1 – Architecture générale du pipeline multi-descripteurs.

2 Histogram of Oriented Gradients (HOG)

2.1 Principe

Le descripteur *Histogram of Oriented Gradients* (HOG) est une méthode largement utilisée pour représenter les formes et les contours présents dans une image.

Le principe consiste à calculer les gradients locaux puis à construire des histogrammes représentant la distribution des orientations dominantes.

Les régions tumorales présentent souvent des structures morphologiques spécifiques qui peuvent être efficacement capturées par cette représentation.

2.2 Hyperparamètres étudiés

Orientations Nombre de directions utilisées pour construire l'histogramme des gradients. Une valeur élevée permet une représentation plus détaillée des contours.

Pixels per Cell Détermine la taille des cellules élémentaires utilisées pour calculer les histogrammes locaux. Ce paramètre influence directement le niveau de détail capturé.

Cells per Block Les cellules sont regroupées en blocs afin d'effectuer une normalisation locale. Cette étape améliore la robustesse du descripteur face aux variations de contraste.

La configuration optimale retenue est : orientations = 6; pixels_per_cell = (16, 16); cells_per_block = (3, 3); block_norm = L2-Hys (score composite : 0.9898).

Le vecteur HOG obtenu fournit une représentation détaillée des structures géométriques présentes dans les images IRM et complète efficacement les informations statistiques, texturales et fréquentielles extraites par les autres descripteurs.




FIGURE 3.2 – Schéma illustratif du calcul HOG : image d'entrée, visualisation des gradients orientés et vecteur de caractéristiques résultant.

3 Caractéristiques statistiques (A)

Les caractéristiques statistiques constituent la forme la plus simple de représentation d'une image. Elles permettent de résumer la distribution globale des intensités des pixels à travers plusieurs indicateurs numériques.

Bien que relativement simples, ces mesures fournissent des informations importantes sur la luminosité, la dispersion et la forme de la distribution des niveaux de gris. Elles sont souvent utilisées comme descripteurs de base dans les systèmes de classification médicale.

Pour chaque image, les caractéristiques suivantes sont extraites :

Moyenne (Mean) La moyenne représente l'intensité moyenne des pixels de l'image :

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i \quad (3.1)$$

où x_i représente l'intensité du pixel i et N le nombre total de pixels. Cette mesure fournit une indication globale du niveau de luminosité de l'image.

Variance La variance mesure la dispersion des intensités autour de la moyenne :

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad (3.2)$$

Une variance élevée indique une forte hétérogénéité des niveaux de gris.

Écart-type (Standard Deviation) L'écart-type correspond à la racine carrée de la variance :

$$\sigma = \sqrt{\sigma^2} \quad (3.3)$$

Il constitue un indicateur direct de la variabilité des intensités.

Entropie L'entropie mesure la diversité de la distribution d'intensités (calculée sur un histogramme normalisé à 64 bins).

Asymétrie (Skewness) L'asymétrie mesure le degré de dissymétrie de la distribution des niveaux de gris. Une valeur positive indique une distribution étirée vers les fortes intensités tandis qu'une valeur négative traduit une concentration vers les faibles intensités.

Kurtosis (Aplatissement) Le kurtosis mesure le degré de concentration des valeurs autour de la moyenne. Cette caractéristique permet de distinguer les distributions présentant des pics prononcés de celles plus étalées.

Le vecteur implémenté (`feat_stats`) regroupe exactement 11 descripteurs : moyenne, écart-type, variance, entropie, asymétrie, kurtosis et les percentiles 10e, 25e, 50e (médiane), 75e et 90e.

L'ensemble de ces mesures constitue le groupe de caractéristiques **A** — **Statistical Features** utilisé dans la suite du projet.

4 Gray Level Co-occurrence Matrix (GLCM)

4.1 Principe

La matrice de cooccurrence des niveaux de gris (*Gray Level Co-occurrence Matrix* — GLCM) est l'une des méthodes les plus utilisées pour l'analyse de texture.

Introduite par Haralick, cette technique repose sur l'étude des relations spatiales entre les pixels voisins. La matrice GLCM comptabilise la fréquence d'apparition de paires de niveaux de gris séparées par une distance et une direction données.

Ainsi, au lieu d'étudier chaque pixel individuellement, la méthode analyse la structure spatiale de l'image, ce qui permet de caractériser efficacement les textures présentes dans les régions tumorales.

4.2 Hyperparamètres étudiés

Dans le cadre de ce projet, plusieurs configurations de GLCM ont été évaluées lors de la phase d'optimisation (Phase 1).

Distances La distance définit l'écart entre les pixels considérés lors du calcul de la matrice. Les distances testées permettent de capturer des textures locales ou plus globales selon l'échelle étudiée.

Angles Les directions utilisées influencent la manière dont les relations spatiales sont observées. Les orientations classiques comprennent :

$$0^\circ, 45^\circ, 90^\circ, 135^\circ \quad (3.4)$$

Ces différentes directions permettent de prendre en compte l'anisotropie potentielle des textures.

Levels Le paramètre *levels* définit le nombre de niveaux de gris utilisés lors de la quantification de l'image. Une quantification appropriée permet de réduire le bruit tout en conservant les structures texturales importantes.

4.3 Caractéristiques extraites

À partir de chaque matrice GLCM, plusieurs indicateurs statistiques sont calculés.

Contrast Mesure les variations locales des niveaux de gris. Des valeurs élevées traduisent généralement des textures fortement contrastées.

Correlation Évalue la dépendance linéaire entre les pixels voisins. Cette mesure permet d'apprécier l'organisation spatiale de la texture.

Energy Mesure l'uniformité de la texture (somme des carrés des probabilités de cooccurrence). Une énergie élevée indique une texture homogène.

Homogeneity Mesure la proximité des valeurs de la matrice par rapport à sa diagonale principale. Une texture homogène présente généralement des valeurs élevées de cette caractéristique.

Dissimilarity et ASM La *dissimilarity* quantifie la variation locale linéaire des niveaux de gris, tandis que l'*ASM* (*Angular Second Moment*) est une mesure complémentaire d'uniformité texturale. Au total, six descripteurs GLCM sont conservés (moyennés sur toutes les paires distance/angle) : contrast, dissimilarity, homogeneity, energy, correlation et ASM.

La configuration optimale retenue est : distances = [1, 2, 4, 8]; angles = [0]; levels = 128; symmetric = False (score composite : 0.7468).




FIGURE 3.3 – Illustration de l'extraction GLCM : image d'entrée et valeurs des descripteurs de texture calculés (meilleurs paramètres Phase 1).

5 Local Binary Patterns (LBP)

5.1 Principe

Le descripteur *Local Binary Patterns* (LBP) est une méthode efficace d'analyse de texture locale.

Son principe consiste à comparer chaque pixel central avec ses voisins. Si l'intensité d'un voisin est supérieure ou égale à celle du pixel central, un bit de valeur 1 est attribué; sinon un bit de valeur 0 est attribué.

La concaténation de ces bits forme un code binaire décrivant la structure locale du voisinage. L'histogramme des codes LBP obtenus constitue ensuite le vecteur de caractéristiques de l'image.

Cette méthode est particulièrement robuste aux variations d'éclairage et largement utilisée pour la reconnaissance de textures.

5.2 Hyperparamètres étudiés

P (Nombre de voisins) Le paramètre P représente le nombre de points de voisinage utilisés pour construire le motif binaire.

R (Rayon) Le rayon R définit la distance entre le pixel central et les pixels voisins. Des rayons plus élevés permettent de capturer des structures plus larges.

Method Plusieurs variantes de LBP ont été testées dans la grille Phase 1 : *uniform*, *nri_uniform* et *ror* (*rotation invariant*). La variante *uniform* retenue produit un histogramme de $P + 2$ bins (soit 14 descripteurs pour $P = 12$).

La configuration optimale retenue est : $P = 12$; $R = 1$; method = uniform (score composite : 0.9906).




FIGURE 3.4 – Illustration de l'extraction LBP : image d'entrée, carte LBP et histogramme des motifs (meilleurs paramètres Phase 1).

6 Discrete Wavelet Transform (DWT)

6.1 Principe

La Transformée en Ondelettes Discrètes (DWT) est une méthode d'analyse fréquentielle permettant de représenter une image simultanément dans les domaines spatial et fréquentiel.

Contrairement à la transformée de Fourier, la DWT conserve une localisation spatiale des informations, ce qui la rend particulièrement adaptée à l'analyse des images médicales.

Lors de la décomposition, l'image est séparée en plusieurs sous-bandes :

- approximation (LL) ;
- détails horizontaux (LH) ;

- détails verticaux (HL);
- détails diagonaux (HH).

Ces sous-bandes permettent de capturer des informations texturales à différentes échelles.

6.2 Familles d'ondelettes

La grille Phase 1 teste les ondelettes suivantes : **haar**, **db1**, **db2**, **db4**, **sym2**, **coif1** et **bior1.3**. Pour chaque sous-bande, quatre statistiques sont calculées : moyenne, écart-type, énergie et entropie.

6.3 Niveaux de décomposition

Le niveau de décomposition contrôle la profondeur de l'analyse multi-résolution. Des niveaux plus élevés permettent de capturer des structures globales tandis que des niveaux faibles privilégient les détails locaux.

Les statistiques calculées sur les coefficients d'ondelettes constituent les caractéristiques DWT utilisées pour la classification.

La configuration optimale retenue est : **wavelet = db2; level = 1** (score composite : 0.9837).




FIGURE 3.5 – Illustration de l'extraction DWT : image d'entrée, sous-bande d'approximation et vecteur de caractéristiques (meilleurs paramètres Phase 1).

7 Synthèse des dimensions par groupe de caractéristiques

Le Tableau 3.1 récapitule la dimension de chaque groupe de caractéristiques (A, B, C, D) avant l'étape de nettoyage, pour la configuration optimale retenue après la Phase 1.

TABLE 3.1 – Dimensions des groupes de caractéristiques avant nettoyage.

Groupe	Contenu	Détail	Dim.
A	Statistiques	mean, std, var, entropy, skew, kurtosis, p10–p90	11
B	Texture	GLCM (6) + LBP (14)	20
C	DWT	Statistiques sur sous-bandes (niveau 1)	16
D	HOG	Histogrammes de gradients orientés	1,944
Full	Fusion A+B+C+D		1,991

La branche HOG constitue de loin le descripteur le plus volumineux, ce qui justifie l'importance des étapes de nettoyage et de réduction de redondance décrites au Chapitre 5.

Chapitre 4

Optimisation des descripteurs (Phase 1)

1 Motivation

L'efficacité d'un système de classification dépend fortement de la qualité des caractéristiques utilisées pour représenter les données. Dans le cas des images IRM cérébrales, les performances finales ne sont pas uniquement influencées par le choix du classificateur, mais également par les paramètres utilisés lors de l'extraction des caractéristiques.

Une approche classique consiste à évaluer directement chaque combinaison de paramètres à travers l'entraînement complet d'un modèle de Machine Learning, généralement via une procédure de type GridSearch associée à une validation croisée. Toutefois, cette stratégie présente plusieurs limitations.

Premièrement, le nombre de combinaisons possibles devient rapidement très important lorsque plusieurs descripteurs sont considérés simultanément. Deuxièmement, chaque évaluation nécessite l'extraction complète des caractéristiques puis l'entraînement d'un ou plusieurs modèles, ce qui entraîne un coût computationnel élevé. Enfin, les résultats obtenus peuvent dépendre du classificateur utilisé, rendant difficile l'évaluation intrinsèque de la qualité des caractéristiques.

Afin de réduire ce coût tout en conservant une évaluation pertinente, nous proposons une phase d'optimisation indépendante des classificateurs. L'idée consiste à mesurer directement la capacité discriminante des caractéristiques extraites à l'aide de métriques statistiques de séparabilité. Cette approche permet d'identifier rapidement les configurations les plus prometteuses avant d'effectuer le benchmark complet des modèles de Machine Learning.

L'optimisation est réalisée séparément pour les descripteurs GLCM, LBP, DWT et HOG afin de sélectionner les paramètres offrant la meilleure capacité de discrimination entre les différentes classes de tumeurs cérébrales.

2 Métriques de séparabilité

Pour évaluer la qualité des caractéristiques extraites, trois métriques complémentaires ont été utilisées. Chacune mesure un aspect particulier de la séparation entre les classes dans l'espace des caractéristiques. Les calculs sont effectués sur l'ensemble d'apprentissage (1,200 images) après extraction des descripteurs pour chaque configuration testée.

2.1 Fisher Discriminant Ratio (FDR)

Le Fisher Discriminant Ratio mesure la capacité d'une caractéristique à séparer différentes classes en comparant la variance inter-classes à la variance intra-classe.

Une caractéristique est considérée comme discriminante lorsque les moyennes des différentes classes sont éloignées tout en conservant une faible dispersion interne.

La formulation générale est donnée par :

$$\text{FDR} = \frac{\sigma_{\text{inter}}^2}{\sigma_{\text{intra}}^2} \quad (4.1)$$

où :

- σ_{inter}^2 représente la variance entre les classes ;
- σ_{intra}^2 représente la variance à l'intérieur des classes.

Dans l'implémentation, le FDR est calculé pour chaque dimension du vecteur de caractéristiques puis moyenné sur l'ensemble des descripteurs. Des valeurs élevées indiquent une meilleure séparation entre les catégories de tumeurs.

2.2 Mutual Information (MI)

L'Information Mutuelle mesure la quantité d'information partagée entre une caractéristique et les étiquettes de classes.

Contrairement au FDR, cette métrique ne suppose pas de relation linéaire entre les variables et permet d'identifier des dépendances plus complexes. L'information mutuelle moyenne est calculée entre chaque dimension et l'étiquette de classe à l'aide de `mutual_info_classif`.

Une valeur élevée de Mutual Information indique qu'une caractéristique apporte une information importante pour distinguer les différentes catégories de tumeurs.

2.3 Davies–Bouldin Index (DBI)

Le Davies–Bouldin Index est une mesure classique de qualité du clustering.

Il évalue simultanément :

- la compacité des classes ;
- la séparation entre les groupes.

Contrairement aux deux métriques précédentes, un score faible indique une meilleure qualité de séparation. Pour des raisons de coût computationnel en haute dimension, le DBI est calculé après une réduction PCA à 20 composantes.

Dans notre procédure d'évaluation, le DBI est inversé après normalisation afin d'être cohérent avec les autres métriques où une valeur élevée correspond à une meilleure configuration.

3 Construction du score composite

Chaque métrique fournit une vision partielle de la qualité des caractéristiques. Afin d'obtenir une évaluation plus robuste, les trois indicateurs sont combinés dans un score composite unique.

Pour chaque grille de recherche (GLCM, LBP, DWT ou HOG), les valeurs de FDR, MI et DBI sont d'abord normalisées par *Min–Max scaling* sur l'ensemble des configurations testées, afin de les rendre comparables sur l'intervalle $[0, 1]$. Le DBI normalisé est ensuite inversé :

$$\text{DBI}_{\text{norm}} = 1 - \text{MinMax}(\text{DBI}) \quad (4.2)$$

Le score final est obtenu par combinaison pondérée à poids égaux :

$$\text{Score}_{\text{composite}} = w_1 \cdot \text{FDR}_{\text{norm}} + w_2 \cdot \text{MI}_{\text{norm}} + w_3 \cdot \text{DBI}_{\text{norm}} \quad (4.3)$$

avec $w_1 = w_2 = w_3 = \frac{1}{3}$ dans notre implémentation.

Cette stratégie permet d'intégrer simultanément :

- la séparation statistique des classes ;
- la pertinence informationnelle des caractéristiques ;
- la compacité des groupes.

Les configurations obtenant les scores composites les plus élevés sont retenues pour la phase suivante du projet.

4 Recherche des meilleurs paramètres

4.1 Optimisation du descripteur GLCM

Pour le descripteur GLCM, plusieurs configurations ont été explorées en faisant varier :

- les distances entre pixels ;
- les orientations ;
- le nombre de niveaux de gris ;
- l'utilisation ou non de matrices symétriques.

Chaque configuration a été évaluée à l'aide du score composite précédemment défini.

Les résultats montrent que la meilleure configuration est obtenue avec : distances = $[1, 2, 4, 8]$; angles = $[0]$; levels = 128; symmetric = False (score composite : 0.7468). Cette combinaison offre le meilleur compromis entre richesse descriptive et capacité discriminante.




FIGURE 4.1 – Évolution du score composite pour les différentes configurations GLCM.

4.2 Optimisation du descripteur LBP

L'algorithme LBP a été optimisé en faisant varier :

- le nombre de voisins (P) ;
- le rayon (R) ;
- la méthode de codage (*uniform*, *nri_uniform*, *ror*).

Après évaluation de l'ensemble des combinaisons testées, la meilleure configuration retenue est : $P = 12$; $R = 1$; method = uniform (score composite : 0.9906). Cette configuration permet de capturer efficacement les textures locales tout en limitant la sensibilité au bruit.




FIGURE 4.2 – Comparaison des scores composites obtenus pour les différentes configurations LBP.

4.3 Optimisation du descripteur DWT

Pour la Transformée en Ondelettes Discrètes, plusieurs familles d'ondelettes et niveaux de décomposition ont été comparés parmi : `haar`, `db1`, `db2`, `db4`, `sym2`, `coif1` et `bior1.3`.

Les expérimentations montrent que la configuration optimale correspond à : `wavelet = db2`; `level = 1` (score composite : 0.9837). Cette configuration fournit les caractéristiques fréquentielles les plus discriminantes pour les images IRM du dataset étudié.




FIGURE 4.3 – Résultats de l'optimisation des paramètres DWT.

4.4 Optimisation du descripteur HOG

L'optimisation du descripteur HOG a porté sur :

- le nombre d'orientations ;
- la taille des cellules (*pixels per cell*) ;
- la taille des blocs (*cells per block*) ;
- la méthode de normalisation (*block norm*).

La meilleure configuration identifiée est : `orientations = 6`; `pixels_per_cell = (16, 16)`; `cells_per_block = (3, 3)`; `block_norm = L2-Hys` (score composite : 0.9898). Cette configuration permet d'obtenir une représentation robuste des contours et des structures géométriques présentes dans les tumeurs cérébrales.




FIGURE 4.4 – Influence des paramètres HOG sur le score composite.

5 Synthèse de la Phase 1

La phase d'optimisation a permis d'identifier les configurations offrant la meilleure capacité de discrimination pour chaque famille de caractéristiques avant toute étape de classification.

TABLE 4.1 – Configurations optimales des descripteurs (Phase 1).

Descripteur	Paramètres optimaux	S
GLCM	distances = [1, 2, 4, 8]; angles = [0]; levels = 128; symmetric = False	0
LBP	$P = 12$; $R = 1$; method = uniform	0
DWT	wavelet = db2; level = 1	0
HOG	orientations = 6; pixels_per_cell = (16, 16); cells_per_block = (3, 3); block_norm = L2-Hys	0

Le Tableau 4.1 résume les paramètres optimaux retenus pour la suite du projet.

Cette première phase a permis de réduire l'espace de recherche tout en sélectionnant les configurations les plus prometteuses. Les paramètres optimaux obtenus serviront de base à la Phase 2, consacrée à la construction des ensembles de caractéristiques, à leur fusion et à l'évaluation comparative des différents algorithmes de Machine Learning.

Chapitre 5

Construction des ensembles de caractéristiques (Phase 2)

1 Construction des ensembles de caractéristiques

Après l'identification des paramètres optimaux lors de la Phase 1, la deuxième phase du projet consiste à construire plusieurs ensembles de caractéristiques afin d'étudier l'apport individuel et combiné des différents descripteurs.

L'objectif est d'évaluer dans quelle mesure les informations statistiques, texturales, fréquentielles et structurelles sont complémentaires pour la classification des tumeurs cérébrales. Pour cela, plusieurs configurations de fusion ont été définies puis comparées à travers un benchmark systématique des modèles de Machine Learning.

Les ensembles étudiés sont présentés dans le Tableau 5.1.

TABLE 5.1 – Ensembles de caractéristiques évalués.

Nom	Contenu
A	Caractéristiques statistiques
B	Texture (GLCM + LBP optimisés)
C	DWT optimisé
D	HOG optimisé
A+B	Statistiques + Texture
B+C	Texture + DWT
A+B+C	Statistiques + Texture + DWT
Full	Statistiques + Texture + DWT + HOG

Chaque ensemble représente un niveau différent de complexité et de richesse descriptive. Les ensembles simples permettent d'évaluer la contribution individuelle de chaque famille de caractéristiques, tandis que les ensembles fusionnés permettent d'analyser leur complémentarité.

La Figure 5.1 illustre le pipeline de construction des huit ensembles à partir des branches A, B, C et D.

1.1 Ensemble A : Caractéristiques statistiques

Cet ensemble regroupe uniquement les 11 mesures statistiques globales extraites des images IRM : moyenne, écart-type, variance, entropie, asymétrie, kurtosis et les percentiles d'intensité (p10 à p90, dont p50 = médiane).

Ces caractéristiques fournissent une représentation compacte de la distribution des niveaux de gris mais ne prennent pas en compte l'organisation spatiale des pixels.




FIGURE 5.1 – Pipeline de construction des ensembles de caractéristiques (Phase 2).

1.2 Ensemble B : Texture (GLCM + LBP)

L'ensemble B combine les informations texturales obtenues à partir des descripteurs GLCM (6 propriétés) et LBP (14 bins, $P = 12$) optimisés en Phase 1, soit 20 dimensions au total.

Cette représentation vise à capturer les relations spatiales entre pixels ainsi que les microstructures locales présentes dans les tissus cérébraux.

1.3 Ensemble C : DWT

Cet ensemble contient exclusivement les 16 caractéristiques fréquentielles extraites par Transformée en Ondelettes Discrètes (ondelette `db2`, niveau 1).

L'objectif est d'étudier la capacité des informations multi-résolutions à discriminer les différentes catégories de tumeurs.

1.4 Ensemble D : HOG

L'ensemble D regroupe les 1,944 caractéristiques issues du descripteur HOG optimisé.

Ces caractéristiques représentent principalement les contours, les gradients et les structures géométriques présentes dans les images.

1.5 Ensembles fusionnés

Afin d'exploiter la complémentarité des différents descripteurs, plusieurs stratégies de fusion ont été étudiées :

- **A+B** : combinaison des informations statistiques et texturales ;
- **B+C** : combinaison des textures et des informations fréquentielles ;
- **A+B+C** : fusion des statistiques, textures et ondelettes ;
- **Full** : fusion de l'ensemble des caractéristiques disponibles (1,991 dimensions brutes).

Cette approche permet d'évaluer l'impact de l'ajout progressif d'informations complémentaires sur les performances de classification.

2 Nettoyage et préparation des caractéristiques

La fusion de plusieurs familles de descripteurs conduit à la génération de vecteurs de grande dimension. Une telle représentation peut contenir des variables redondantes ou peu informatives susceptibles de dégrader les performances des modèles.

Afin d'améliorer la qualité des données et de réduire le risque de surapprentissage, une procédure de nettoyage a été appliquée à chaque ensemble de caractéristiques avant l'entraînement des modèles.

2.1 Suppression des caractéristiques à faible variance

La première étape consiste à appliquer un filtre basé sur la variance (*Variance Threshold*, seuil = 0).

Les variables dont la variance est proche de zéro apportent généralement peu d'information discriminante puisqu'elles prennent pratiquement la même valeur pour l'ensemble des observations.

La suppression de ces caractéristiques permet :

- de réduire la dimension des données ;
- d'éliminer les variables non informatives ;
- d'accélérer les étapes ultérieures de traitement.

Cette opération constitue un premier niveau de sélection automatique des caractéristiques.

2.2 Élimination des caractéristiques fortement corrélées

La présence de variables fortement corrélées introduit une redondance importante dans la représentation des données.

Pour limiter ce phénomène, une matrice de corrélation est calculée sur l'ensemble des caractéristiques. Lorsqu'une paire de variables présente une corrélation absolue supérieure au seuil $\rho = 0,95$, l'une des deux variables est supprimée.

Cette étape permet :

- de réduire la multicollinéarité ;
- d'améliorer la stabilité des modèles ;
- de diminuer la complexité des ensembles fusionnés.

La suppression des variables redondantes est particulièrement importante pour les ensembles comportant plusieurs milliers de caractéristiques, comme HOG ou Full.

2.3 Standardisation des caractéristiques

Les différentes familles de descripteurs produisent des variables dont les échelles peuvent être très différentes. Par exemple, certaines caractéristiques statistiques prennent des valeurs comprises entre 0 et 1, tandis que certaines caractéristiques HOG ou DWT peuvent atteindre des amplitudes beaucoup plus élevées.

Afin d'assurer une contribution équilibrée de chaque variable lors de l'apprentissage, une standardisation (**StandardScaler**) est appliquée à l'ensemble des caractéristiques après nettoyage. Chaque variable est transformée selon :

$$z = \frac{x - \mu}{\sigma} \quad (5.1)$$

où x représente la valeur initiale, μ la moyenne et σ l'écart-type estimés sur l'ensemble d'apprentissage.

Cette transformation produit des variables centrées et réduites, facilitant l'apprentissage des modèles sensibles à l'échelle des données tels que SVM, KNN, Logistic Regression et MLP.

3 Réduction de la redondance et analyse des dimensions

L'une des conséquences directes de la fusion de plusieurs descripteurs est l'augmentation significative du nombre de variables. Une analyse de la réduction dimensionnelle obtenue après le nettoyage a donc été réalisée.

Pour chaque ensemble de caractéristiques, les éléments suivants ont été étudiés :

- nombre initial de caractéristiques ;
- nombre de caractéristiques supprimées ;
- nombre final de caractéristiques conservées ;
- ratio de conservation.

Le ratio de conservation est défini par :

$$\text{Ratio}_{\text{conservation}} = \frac{N_{\text{conservées}}}{N_{\text{initial}}} \times 100 \quad (5.2)$$

Cette mesure permet d'évaluer l'impact du processus de nettoyage sur chaque ensemble.

Le Tableau 5.2 et les Figures 5.2 et 5.3 synthétisent les résultats obtenus.

TABLE 5.2 – Dimensions avant et après nettoyage pour chaque ensemble.

Ensemble	Brut	Après var.	Nettoyé	Supprimé	Conservé (%)
A	11	11	9	2	81,8
B	20	20	18	2	90,0
C	16	16	12	4	75,0
D	1944	1944	490	1454	25,2
A+B	31	31	27	4	87,1
B+C	36	36	30	6	83,3
A+B+C	47	47	36	11	76,6
Full	1991	1991	526	1465	26,4

Les résultats montrent que les ensembles de grande dimension, notamment ceux incluant HOG et les combinaisons fusionnées, présentent une proportion importante de caractéristiques redondantes. À l'inverse, l'ensemble statistique A possède naturellement une dimension réduite et nécessite peu de filtrage.




FIGURE 5.2 – Ratio de conservation des caractéristiques après nettoyage.

L'application conjointe du *Variance Threshold* et de l'élimination des corrélations permet ainsi de conserver uniquement les caractéristiques les plus informatives tout en réduisant significativement la complexité des données. L'ensemble Full passe par exemple de 1991 à 526 variables (soit 26,4% conservées).

Cette étape constitue un élément essentiel du pipeline, car elle améliore à la fois la robustesse des modèles, leur temps d'entraînement et leur capacité de généralisation.

La Figure 5.4 illustre la séparabilité visuelle des trois classes dans l'espace des caractéristiques de l'ensemble fusionné complet après nettoyage.

3.1 Synthèse de la Phase 2

À l'issue de cette phase, huit ensembles de caractéristiques nettoyés et standardisés sont obtenus. Ces représentations serviront de base au benchmark des algorithmes de Machine Learning présenté au chapitre suivant.




FIGURE 5.3 – Comparaison des dimensions des ensembles avant et après réduction.




FIGURE 5.4 – Projection t-SNE (2D) de l'ensemble Full(opt) nettoyé (526 caractéristiques) sur l'ensemble d'apprentissage.

L'objectif sera alors d'évaluer l'impact de chaque famille de descripteurs ainsi que l'intérêt des stratégies de fusion sur les performances de classification des tumeurs cérébrales.

Chapitre 6

Benchmark des modèles de Machine Learning

1 Modèles évalués

L'objectif principal de cette phase est d'identifier la combinaison la plus performante entre les ensembles de caractéristiques construits lors de la Phase 2 et différents algorithmes de Machine Learning. Afin d'obtenir une évaluation exhaustive, huit modèles de classification représentant différentes familles d'apprentissage supervisé ont été sélectionnés.

1.1 Support Vector Machine (SVM)

Le Support Vector Machine est un classificateur fondé sur la recherche d'un hyperplan optimal maximisant la marge entre les différentes classes. Grâce à l'utilisation de fonctions noyaux, il est capable de traiter efficacement des données non linéaires et de grande dimension.

Le SVM est particulièrement adapté aux problèmes de classification médicale impliquant un nombre élevé de caractéristiques, ce qui en fait un candidat naturel pour les ensembles fusionnés étudiés dans ce projet.

1.2 K-Nearest Neighbors (KNN)

Le classificateur KNN repose sur un mécanisme de vote majoritaire parmi les k voisins les plus proches d'un échantillon.

Sa simplicité et son absence d'hypothèses fortes sur la distribution des données en font une référence classique pour les tâches de classification multiclassées.

1.3 Random Forest (RF)

Random Forest est une méthode d'apprentissage par ensemble basée sur la construction de plusieurs arbres de décision indépendants.

La prédiction finale est obtenue par vote majoritaire des arbres individuels. Cette approche offre généralement une bonne robustesse face au bruit et aux variables redondantes.

1.4 Extra Trees (ET)

L'algorithme Extra Trees constitue une variante plus aléatoire de Random Forest.

L'introduction d'une randomisation supplémentaire lors de la construction des arbres permet souvent de réduire la variance du modèle tout en conservant une bonne capacité de généralisation.

1.5 Logistic Regression (LR)

La Régression Logistique est un modèle linéaire probabiliste largement utilisé comme référence dans les études comparatives.

Bien qu'elle soit plus simple que les autres modèles évalués, elle permet d'analyser la séparabilité intrinsèque des ensembles de caractéristiques.

1.6 Multi-Layer Perceptron (MLP)

Le Multi-Layer Perceptron est un réseau de neurones artificiel composé de plusieurs couches entièrement connectées.

Grâce à ses fonctions d'activation non linéaires, il est capable de modéliser des frontières de décision complexes et d'apprendre des relations non linéaires entre les caractéristiques.

1.7 XGBoost

XGBoost (*Extreme Gradient Boosting*) est une méthode de boosting basée sur l'agrégation séquentielle d'arbres de décision.

Son efficacité, sa robustesse et sa capacité à gérer des données de grande dimension en font l'un des algorithmes les plus performants dans de nombreux problèmes de classification.

1.8 LightGBM

LightGBM est une implémentation optimisée du Gradient Boosting développée pour offrir des temps d'entraînement réduits et une meilleure gestion des grands ensembles de données.

Sa structure efficace lui permet de construire rapidement des modèles performants tout en limitant la consommation mémoire.

2 Stratégie d'évaluation

Afin d'assurer une comparaison équitable entre les différents modèles, une procédure d'évaluation rigoureuse a été mise en place.

2.1 Optimisation des hyperparamètres par GridSearchCV

Chaque algorithme possède plusieurs hyperparamètres susceptibles d'influencer fortement ses performances.

Afin d'identifier automatiquement les meilleures configurations, une recherche par grille (*Grid Search*) a été réalisée à l'aide de la méthode **GridSearchCV** de Scikit-Learn.

Cette procédure consiste à :

1. générer toutes les combinaisons possibles d'hyperparamètres ;
2. entraîner le modèle pour chaque combinaison ;
3. évaluer les performances via validation croisée ;
4. retenir la configuration obtenant le meilleur score moyen.

Cette approche garantit que chaque modèle est évalué dans des conditions optimales.

2.2 Validation croisée stratifiée

Pour réduire l'impact des variations liées à la partition des données, une validation croisée stratifiée à 5 plis (*Stratified 5-Fold Cross Validation*) a été utilisée sur l'ensemble d'apprentissage (1,200 images).

Le principe consiste à :

- diviser le jeu d'apprentissage en cinq sous-ensembles ;
- utiliser successivement quatre plis pour l'entraînement et un pli pour la validation ;
- répéter l'opération cinq fois ;
- calculer la moyenne des performances obtenues.

L'utilisation d'une stratégie stratifiée permet de conserver la proportion des classes dans chaque pli.

2.3 Métrique d'évaluation : F1-Macro

La métrique principale retenue dans ce projet est le **F1-Macro Score**, utilisée à la fois pour la sélection des hyperparamètres (score de validation croisée) et pour le classement final sur l'ensemble de test (300 images).

Cette mesure combine la précision (*Precision*) et le rappel (*Recall*) :

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (6.1)$$

Dans sa version Macro, le score est calculé indépendamment pour chaque classe puis moyenné.

Cette approche est particulièrement adaptée aux problèmes multiclasses car elle accorde le même poids à chaque catégorie de tumeur.

Le F1-Macro constitue ainsi un indicateur robuste de la performance globale des modèles.

3 Résultats détaillés

Chaque combinaison « Ensemble de caractéristiques × Modèle » a été évaluée selon la procédure décrite précédemment.

Au total, huit ensembles de caractéristiques ont été testés sur huit algorithmes de Machine Learning, soit **64 expériences** distinctes. Les résultats complets sont présentés dans l'Annexe ?? . Ils permettent d'analyser :

- l'influence du choix des caractéristiques ;
- l'impact de la fusion des descripteurs ;
- les différences de comportement entre les algorithmes ;
- la stabilité des performances observées.

Les premières observations montrent que les ensembles fusionnés obtiennent généralement de meilleurs résultats que les ensembles individuels, confirmant l'intérêt de combiner plusieurs sources d'information visuelle.

Par ailleurs, les modèles non linéaires tels que SVM, KNN, LightGBM et XGBoost bénéficient davantage de la richesse descriptive apportée par les ensembles de caractéristiques fusionnés.

Les Figures 6.1 à 6.8 présentent les performances détaillées (F1-Macro, précision, rappel et matrices de confusion) pour chaque ensemble de caractéristiques.



FIGURE 6.1 – Comparaison des modèles sur l'ensemble A (Statistiques).

4 Leaderboard global

Afin d'identifier les meilleures configurations du projet, l'ensemble des résultats a été regroupé dans un classement global basé sur le F1-Macro obtenu sur l'ensemble de test.




FIGURE 6.2 – Comparaison des modèles sur l'ensemble B (Texture optimisée).




FIGURE 6.3 – Comparaison des modèles sur l'ensemble C (DWT optimisé).




FIGURE 6.4 – Comparaison des modèles sur l'ensemble D (HOG).




FIGURE 6.5 – Comparaison des modèles sur l'ensemble fusionné A+B.




FIGURE 6.6 – Comparaison des modèles sur l'ensemble fusionné B+C.




FIGURE 6.7 – Comparaison des modèles sur l'ensemble fusionné A+B+C.




FIGURE 6.8 – Comparaison des modèles sur l'ensemble Full (fusion complète).

TABLE 6.1 – Leaderboard global — Top 10 (F1-Macro sur l'ensemble de test).

Rang	Modèle	Ensemble	F1-Macro
1	SVM	Full(opt)	0,920
2	SVM	D (HOG)	0,903
3	KNN	Full(opt)	0,900
4	KNN	D (HOG)	0,897
5	LightGBM	Full(opt)	0,894
6	MLP	Full(opt)	0,884
7	XGBoost	Full(opt)	0,880
8	Extra Trees	Full(opt)	0,877
9	MLP	D (HOG)	0,877
10	LR	Full(opt)	0,870

Le Tableau 6.1 présente les dix combinaisons les plus performantes (source : `phase2_benchmark_results.csv`).

La Figure 6.9 visualise ce classement ; la Figure 6.10 offre une vue d'ensemble des performances sur l'ensemble des 64 expériences.




FIGURE 6.9 – Leaderboard global des combinaisons modèle × ensemble de caractéristiques.

L'analyse du leaderboard met en évidence plusieurs tendances importantes.

Premièrement, les ensembles de caractéristiques fusionnés dominent largement les ensembles individuels, ce qui confirme l'existence d'une forte complémentarité entre les informations statistiques, texturales, fréquentielles et structurales. L'ensemble **Full(opt)** apparaît dans sept des dix meilleures configurations.

Deuxièmement, le modèle **SVM** obtient les meilleures performances globales (F1-Macro = 0,920 sur Full(opt)). Ce résultat confirme sa capacité à exploiter efficacement des espaces de caractéristiques de grande dimension tout en maintenant une excellente capacité de généralisation.

Troisièmement, les modèles **KNN** et **LightGBM** occupent également les premières positions du classement, démontrant que les informations extraites possèdent une forte capacité discriminante indépendamment du paradigme d'apprentissage utilisé.

Enfin, l'ensemble **D (HOG)** seul atteint des performances proches de Full(opt) avec SVM et KNN (rangs 2 et 4), soulignant l'apport majeur des descripteurs de contours dans ce problème de classification.

Ces observations seront approfondies dans le chapitre suivant à travers une validation statistique complète visant à évaluer la robustesse et la significativité des différences observées entre les modèles.

Overall Dashboard — Optimal Feature Parameters + Model Benchmark




FIGURE 6.10 – Tableau de bord global du benchmark Phase 2.

Chapitre 7

Validation statistique

1 Coefficient de Cohen's Kappa

L'exactitude (*Accuracy*) constitue une mesure couramment utilisée pour évaluer les performances d'un classificateur. Toutefois, cette métrique ne tient pas compte des accords pouvant être obtenus par hasard. Afin de fournir une évaluation plus robuste, le coefficient de Cohen's Kappa (κ) a été calculé pour les meilleures configurations du benchmark.

Le coefficient Kappa mesure le niveau d'accord entre les prédictions du modèle et les étiquettes réelles après correction de l'accord aléatoire :

$$\kappa = \frac{P_o - P_e}{1 - P_e} \quad (7.1)$$

où P_o représente l'accord observé et P_e l'accord attendu par hasard.

Les valeurs de κ sont généralement interprétées comme suit :

TABLE 7.1 – Interprétation du coefficient κ .

Valeur de κ	Interprétation
$< 0,20$	Accord faible
$0,21 - 0,40$	Accord acceptable
$0,41 - 0,60$	Accord modéré
$0,61 - 0,80$	Accord substantiel
$> 0,80$	Accord presque parfait

Les résultats obtenus montrent des valeurs de Kappa élevées pour les meilleures configurations. Le modèle **SVM avec l'ensemble Full(opt)** atteint $\kappa = 0,88$, tandis que :

- KNN + Full(opt) : $\kappa = 0,85$;
- LightGBM + Full(opt) : $\kappa = 0,84$.

Ces valeurs indiquent un niveau d'accord presque parfait entre les prédictions et les classes réelles, confirmant la qualité des modèles développés.

2 Intervalles de confiance Bootstrap

Afin d'évaluer la stabilité des performances observées sur le jeu de test, une procédure Bootstrap a été appliquée ($N = 2000$ rééchantillonnages avec remise).

Cette méthode permet d'estimer un intervalle de confiance à 95 % à partir de la distribution des métriques recalculées sur chaque échantillon bootstrap.

Pour le meilleur modèle (**SVM + Full(opt)**), les résultats obtenus sont :

Ces intervalles relativement étroits témoignent d'une faible variabilité des performances et confirment la robustesse du modèle.

TABLE 7.2 – Intervalles de confiance Bootstrap — SVM + Full(opt).

Métrique	Valeur test	IC 95 % bas	IC 95 % haut
Accuracy	0,920	0,890	0,950
F1-Macro	0,9204	0,8895	0,9504

Le Tableau 7.3 synthétise les dix meilleures configurations avec Accuracy, F1-Macro, κ et bornes d’intervalles de confiance Bootstrap (source : `statistical_validation_summary.csv`).

TABLE 7.3 – Top 10 — Accuracy, F1-Macro, κ et IC 95 % Bootstrap.

Ensemble	Modèle	Acc.	F1	κ	F1 IC bas	F1 IC haut
Full(opt)	SVM	0,920	0,920	0,880	0,890	0,950
D (HOG)	SVM	0,903	0,903	0,855	0,868	0,935
Full(opt)	KNN	0,900	0,900	0,850	0,866	0,932
D (HOG)	KNN	0,897	0,897	0,845	0,863	0,928
Full(opt)	LightGBM	0,893	0,894	0,840	0,859	0,927
Full(opt)	MLP	0,883	0,884	0,825	0,846	0,919
Full(opt)	XGBoost	0,880	0,880	0,820	0,843	0,915
D (HOG)	MLP	0,877	0,877	0,815	0,838	0,912
Full(opt)	Extra Trees	0,877	0,877	0,815	0,840	0,912
Full(opt)	LR	0,870	0,870	0,805	0,831	0,905




FIGURE 7.1 – Intervalles de confiance Bootstrap (F1-Macro et Accuracy) pour les meilleurs modèles sur Full(opt).

De manière générale, les meilleurs modèles présentent des intervalles de confiance fortement chevauchants mais centrés sur des valeurs élevées, ce qui renforce la fiabilité des résultats obtenus.

3 Analyse par validation croisée

La validation croisée stratifiée à cinq plis utilisée durant le benchmark permet d’étudier la stabilité des performances selon les différentes partitions des données d’apprentissage.

3.1 Moyenne des performances

Sur l'ensemble de **test** (300 images), le modèle SVM + Full(opt) atteint une accuracy de **92,0 %** et un F1-Macro de **92,04 %**. Les scores moyens obtenus sur les cinq plis de validation croisée (jeu d'apprentissage) sont légèrement inférieurs, ce qui est attendu : F1-Macro moyen CV = 89,5 %, accuracy moyenne CV = 89,5 %.

Ces résultats confirment que les performances observées sur le jeu de test ne sont pas dues à une partition particulière des données.

3.2 Écart-type des performances

L'écart-type des scores obtenus sur les différents plis constitue un indicateur de stabilité. Pour SVM + Full(opt) :

- Accuracy Std (CV) = 0,0099 ;
- F1 Std (CV) = 0,0100.

Ces valeurs particulièrement faibles indiquent que les performances restent constantes quelle que soit la partition utilisée. Les autres modèles du Top 5 sur Full(opt) présentent également des écarts-types inférieurs à 0,02.

Le Tableau 7.4 résume les moyennes et écarts-types CV pour les cinq meilleurs modèles sur Full(opt) (source : `cv_fold_statistics.csv`).

TABLE 7.4 – Validation croisée (5 plis) — moyenne $\pm$ écart-type sur Full(opt).

Modèle	F1-Macro (moy. $\pm$ std)	Accuracy (moy. $\pm$ std)
SVM	0,895 $\pm$ 0,010	0,895 $\pm$ 0,010
LightGBM	0,878 $\pm$ 0,009	0,878 $\pm$ 0,008
Extra Trees	0,878 $\pm$ 0,004	0,879 $\pm$ 0,004
KNN	0,870 $\pm$ 0,020	0,871 $\pm$ 0,020
MLP	0,873 $\pm$ 0,011	0,873 $\pm$ 0,011

4 Test de McNemar

Le test de McNemar est un test statistique non paramétrique utilisé pour comparer directement deux classificateurs sur les mêmes observations (ici, l'ensemble de test, configuration **Full(opt)**).

L'hypothèse nulle H_0 postule que les deux modèles ont des performances équivalentes. Une valeur $p < 0,05$ conduit au rejet de H_0 .

Le Tableau 7.5 présente les comparaisons clés entre les modèles du Top 5 (source : `mcnemar_test_results.csv`).

TABLE 7.5 – Test de McNemar — paires sélectionnées (Full(opt), $n = 300$).

Modèle A	Modèle B	n_{01}	n_{10}	p -value
SVM	KNN	20	14	0,391
SVM	LightGBM	14	6	0,118
SVM	MLP	15	4	0,022
SVM	XGBoost	17	5	0,019
SVM	Extra Trees	18	5	0,012
SVM	LR	19	4	0,004
KNN	LightGBM	20	18	0,871

Les résultats montrent que SVM est significativement meilleur que LR, MLP, XGBoost et Extra Trees ($p < 0,05$), mais que la différence avec **KNN** ($p = 0,391$) et **LightGBM** ($p = 0,118$) n'est pas statistiquement significative au seuil de 5 %.

5 Test de Wilcoxon

Le test des rangs signés de Wilcoxon permet de comparer les performances de deux modèles à partir des scores F1-Macro obtenus sur les cinq plis de validation croisée.

L'hypothèse nulle est : H_0 : la médiane des différences entre les deux modèles est nulle.

Pour Full(opt), les comparaisons entre SVM et les autres modèles du Top 5 donnent des p -values $\geq 0,0625$ (seuil non atteint à 5 %), indiquant qu'au regard des scores CV, les écarts observés ne sont pas statistiquement significatifs — cohérent avec le test de McNemar pour SVM vs KNN/LightGBM.

6 Tests de Friedman et Nemenyi

Lorsque plusieurs modèles doivent être comparés simultanément, une analyse globale a été réalisée à l'aide du test de Friedman sur les huit ensembles de caractéristiques (A, B, C, D, A+B, B+C, A+B+C, Full).

Pour **tous** les ensembles testés, le test de Friedman rejette H_0 au seuil de 5 % ($p < 0,01$), confirmant que les huit algorithmes ne sont pas équivalents. Les statistiques les plus élevées sont observées pour B — Tex(opt) ($\chi^2 = 32,2$, $p < 10^{-4}$) et A+B+C(opt) ($\chi^2 = 29,7$, $p = 1,06 \times 10^{-4}$).

En cas de rejet, un test post-hoc de Nemenyi a été appliqué pour identifier les paires de modèles significativement différentes au sein de chaque ensemble de caractéristiques.




FIGURE 7.2 – Valeurs p du test de Friedman par ensemble de caractéristiques (comparaison simultanée des 8 modèles).

TABLE 7.6 – Résultats du test de Friedman par ensemble de caractéristiques.

Ensemble	Statistique	p -value	Significatif
B — Tex(opt)	32,20	$3,7 \times 10^{-5}$	Oui
A+B+C(opt)	29,73	$1,1 \times 10^{-4}$	Oui
A+B	28,20	$2,0 \times 10^{-4}$	Oui
B+C(opt)	25,60	$5,9 \times 10^{-4}$	Oui
A — Stats	24,60	$8,9 \times 10^{-4}$	Oui
C — DWT(opt)	24,27	$1,0 \times 10^{-3}$	Oui
Full(opt)	23,60	$1,3 \times 10^{-3}$	Oui
D — HOG	22,33	$2,2 \times 10^{-3}$	Oui

7 Synthèse statistique

Les analyses statistiques réalisées dans ce projet permettent de compléter l'évaluation classique basée sur les métriques de performance.

Les principaux enseignements sont les suivants :

- les meilleurs modèles présentent des coefficients de Cohen's Kappa supérieurs à 0,80, indiquant un accord presque parfait avec les annotations réelles ;
- les intervalles de confiance Bootstrap demeurent relativement étroits, témoignant d'une bonne stabilité des performances sur le jeu de test ;
- les faibles écarts-types observés lors de la validation croisée ($\leq 0,02$ pour le Top 5 sur Full) montrent une excellente capacité de généralisation ;
- le test de McNemar confirme la supériorité de SVM sur plusieurs modèles, mais pas sur KNN et LightGBM au seuil de 5 % ;
- le test de Friedman rejette l'équivalence des huit algorithmes sur chaque ensemble de caractéristiques ;
- les ensembles fusionnés obtiennent systématiquement des performances supérieures aux ensembles individuels.

Parmi l'ensemble des configurations étudiées, **SVM associé à Full(opt)** apparaît comme la solution la plus performante et la plus robuste.

Avec une accuracy de **92,0 %**, un F1-Macro de **92,04 %**, un coefficient $\kappa = 0,88$, des intervalles Bootstrap étroits et des écarts-types CV inférieurs à 0,01, cette configuration constitue le meilleur compromis entre performance, stabilité et capacité de généralisation.

Ces résultats valident l'efficacité de la stratégie proposée reposant sur l'optimisation des descripteurs, la fusion multi-caractéristiques et l'évaluation comparative de plusieurs algorithmes de Machine Learning.

Chapitre 8

Analyse et discussion

1 Analyse des performances

Le benchmark (Chapitre 6) place le **SVM** avec l'ensemble **Full(opt)** en tête (F1-Macro = 0,920, Accuracy = 0,920 ; Tableau 6.1, Figure 6.9).

Cette domination s'explique par trois facteurs : (i) l'espace de grande dimension (1,991 variables brutes, 526 après nettoyage), où les SVM à marge maximale sont efficaces ; (ii) la non-linéarité des relations, capturée par le noyau polynomial retenu (**kernel=poly**, $C = 10$), contrairement aux modèles linéaires (LR : F1 = 0,870 sur Full(opt)) ; (iii) la bonne séparabilité des classes dans l'espace optimisé (Figure 5.4).

KNN (0,900) et LightGBM (0,894) restent compétitifs, mais McNemar (Chapitre 7) ne confirme pas de supériorité significative du SVM face à KNN ($p = 0,391$) ni LightGBM ($p = 0,118$) au seuil de 5 %.

2 Contribution des branches de caractéristiques

Le Tableau 8.1 résume la meilleure combinaison modèle $\times$ ensemble par branche sur le jeu de test.

TABLE 8.1 – Meilleur F1-Macro par branche de caractéristiques (ensemble de test).

Branches	Ensemble	Meilleur modèle	F1-Macro
A — Statistiques	A — Stats	SVM	0,787
B — Texture	B — Tex(opt)	XGBoost	0,827
C — Fréquentiel	C — DWT(opt)	Extra Trees	0,760
D — Structurel	D — HOG	SVM	0,903
Fusion complète	Full(opt)	SVM	0,920

Les statistiques (A) restent limitées seules (0,787) mais apportent un signal complémentaire. La texture (B, GLCM+LBP) atteint 0,827 et confirme le rôle des motifs locaux. La DWT (C) est la branche la plus faible isolément (0,760), tout en capturant des variations multi-échelles. Le HOG (D) domine à lui seul (0,903), seulement 1,7 point sous Full(opt), ce qui souligne l'apport des contours et structures anatomiques.

L'importance par branche (Random Forest sur Full(opt), Figure 8.1) corrobore cette hiérarchie : HOG ≈ 72 %, puis Stats (8,6 %), LBP (8,2 %), DWT (5,8 %) et GLCM (5,0 %).

3 Effet de la fusion

La fusion multi-descripteurs améliore systématiquement les branches faibles (A, C) et dépasse légèrement la meilleure branche isolée : Full(opt) (0,920) surpasse D (HOG) (0,903). Les familles statistiques, texturales, fréquentielles et structurelles capturent des aspects complémentaires de l'image ;




FIGURE 8.1 – Importance cumulée des branches de caractéristiques (Random Forest sur Full(opt)).

leur combinaison réduit les ambiguïtés inter-classes (Figure 5.4) et se traduit par la domination de Full(opt) dans le classement global (Figure 6.10).

4 Comparaison avec la littérature

Les approches profondes (VGG, ResNet, ViT, etc.) rapportent souvent $> 98\%$ de précision, parfois $> 99\%$ en configuration hybride. Nos 92% de F1-Macro restent inférieurs, mais dans un cadre différent : caractéristiques manuelles, huit classifieurs classiques, dataset modeste (1,500 images) et protocole explicitement orienté interprétabilité.

L'intérêt méthodologique réside dans l'optimisation systématique des descripteurs (Phase 1), le benchmark exhaustif (64 expériences), la validation statistique (Kappa, Bootstrap, McNemar, Friedman) et l'analyse d'importance par branche — éléments souvent absents des travaux purement orientés score.

5 Limites et perspectives

Dataset et protocole. Le volume limité (1,200 / 300) et l'usage de coupes 2D sans segmentation tumorale peuvent restreindre la généralisation et laisser du bruit de fond dans les descripteurs.

Choix méthodologique. L'absence de Deep Learning dans le pipeline principal limite le plafond de performance, au profit d'un coût computationnel réduit et d'une meilleure traçabilité des variables.

Pistes. Segmentation automatique, volumes IRM 3D, fusion ML/DL, datasets multicentriques et explicabilité (XAI) constituent les prolongements naturels de ce travail (Chapitre 9).

Chapitre 9

Extensions exploratoires : Deep Learning et VLM

Au-delà du pipeline ML des chapitres précédents, deux notebooks complémentaires ont été réalisés : `Deep_learning.ipynb` (benchmark CNN et modèles hybrides, Phase 3) et `VLM.ipynb` (fine-tuning d'un modèle vision-langage avec LoRA). Cette section en résume le protocole, les figures clés et les résultats principaux.

1 Benchmark Deep Learning (`Deep_learning.ipynb`)

1.1 Protocole

Le notebook implémente une **Phase 3** structurée en trois niveaux, sur le même jeu de données (1,200 / 300) et les mêmes caractéristiques manuelles optimisées (Phase 1) :

- **Tier 0 — CNN purs** : VGG16, ResNet50, EfficientNet-B0 et ViT-B/16 (transfert ImageNet, tête de classification entraînée).
- **Tier 1 — Hybrides** : ResNet18 + une branche manuelle (GLCM, LBP, DWT ou HOG) concaténée aux embeddings CNN (`HybridClassifier`).
- **Tier 2 — Fusion profonde** : ResNet18 + les quatre branches manuelles fusionnées par concaténation (`MultiBranchFusion`) ou attention apprise (`AttentionFusion`).

Chaque modèle est évalué en *hold-out* (split 80/20 stratifié) et en validation croisée 5-fold. Les métriques sont exportées dans `results/phase3_all_metrics.csv`.

1.2 Résultats principaux

Le Tableau 9.1 et la Figure 9.1 rapportent les F1-Macro sur le split de test. Le meilleur modèle pur est **ResNet50** ($F1 = 0,935$), devant EfficientNet-B0 (0,926) et VGG16 (0,910). ViT-B/16 sous-performe sur ce petit corpus (0,842).

Les hybrides Tier 1 surpassent nettement les branches ML correspondantes de la Phase 2 : par exemple, `cnn_hog` atteint $F1 = 0,934$ contre 0,903 pour SVM + D (HOG), et `waveletcnn` atteint 0,917 contre 0,760 pour Extra Trees + C (DWT).

En Tier 2, la fusion profonde n'apporte qu'un gain marginal sur Full(opt) de la Phase 2 : `multibranch_fusion` (0,923) dépasse SVM + Full(opt) (0,920) de +0,002, tandis que `attention_fusion` reste en dessous (0,901).

La Figure 9.2 montre les courbes ROC one-vs-rest pour l'ensemble des dix modèles Phase 3. ResNet50 et les hybrides Tier 1 dominent sur les trois classes, confirmant la bonne séparabilité des tumeurs dans l'espace des représentations apprises.

La matrice de confusion de ResNet50 (Figure 9.3) confirme un faible taux d'erreurs inter-classes, avec une légère confusion entre gliome et méningiome.

TABLE 9.1 – Phase 3 — meilleurs résultats par tier (split de test).

Tier	Modèle	F1-Macro	Accuracy
0	ResNet50	0,935	0,941
0	EfficientNet-B0	0,926	0,933
0	VGG16	0,910	0,915
1	CNN + HOG	0,934	0,940
1	LBPNet	0,934	0,940
2	MultiBranchFusion	0,923	0,930
<i>Réf. Phase 2 — SVM + Full(opt)</i>		0,920	0,920





FIGURE 9.1 – Comparaison des F1-Macro par modèle et par tier (split de test).

ROC — all trained models






FIGURE 9.3 – Matrice de confusion normalisée — ResNet50 (Tier 0, split de test).

Pour l'interprétabilité, le notebook génère des cartes Grad-CAM (Figure 9.4). ResNet50 (Tier 0) et CNN+HOG (Tier 1) focalisent l'attention sur la région tumorale, validant visuellement la pertinence des représentations apprises.

2 Exploration VLM (VLM.ipynb)

2.1 Objectif et architecture

Ce second notebook explore un **modèle vision-langage** appliqué à la même tâche de classification en trois classes (Glioma, Meningioma, Pituitary Tumor). Le modèle retenu est **Qwen2.5-VL-7B-Instruct**, chargé en **quantification 4-bit NF4** pour tenir sur une GPU ~16 GiB, puis adapté par **LoRA** ($r = 8$, $\alpha = 16$, ~0,3 % de paramètres entraînaables sur 8,3 G de poids gelés).

L'image et une consigne textuelle sont fournies au modèle ; la réponse attendue est le nom de la classe tumorale. Le jeu est découpé en 1 050 / 150 / 300 échantillons (train / val / test).

2.2 Teacher Forcing et sondes de probabilité

Le notebook se concentre sur deux mécanismes fondamentaux du fine-tuning VLM :

- **Teacher Forcing** : pendant l'entraînement, les tokens de la réponse correcte sont fournis comme contexte ; un masque de labels restreint la perte aux seuls tokens de l'assistant (Figure 9.5).
- **Sondes de probabilité** : avant et après LoRA, le notebook mesure la probabilité assignée à chaque token de classe à la première position de génération (Figures 9.6 et 9.8).

Un *QA Monitor* interroge le modèle à intervalles réguliers pendant l'entraînement (5 époques, batch size 1, learning rate 2×10^{-4}) pour suivre l'évolution des probabilités de classe (Figure 9.7).

2.3 Résultats

Avant fine-tuning, le modèle généraliste distribue les probabilités de façon peu discriminante sur les classes tumorales. Après LoRA, les sondes montrent un recentrage net sur le token de la classe correcte, et le monitor atteint 3/3 sur les échantillons-sondes dès les premières étapes d'évaluation.




FIGURE 9.4 – Grad-CAM sur un cas correctement classifié par modèle : ResNet50 (gauche) et CNN+HOG (droite).




FIGURE 9.5 – Masque de labels en mode Teacher Forcing : seuls les tokens de la réponse assistant contribuent à la perte.




FIGURE 9.6 – Sonde zero-shot : probabilités des tokens de classe avant fine-tuning LoRA (un échantillon par classe).




FIGURE 9.7 – Courbes d’entraînement (gauche) et précision du QA Monitor sur les échantillons-sondes (droite).




FIGURE 9.8 – Probabilités des tokens de classe avant vs après LoRA (gauche) et évolution per-token en teacher-forcing (droite).




FIGURE 9.9 – Heatmap de la perte cross-entropie (teacher-forcing) avant vs après fine-tuning.

Sur le jeu de test ($n = 300$), la génération greedy atteint une **accuracy globale de 94,7 %** (F1 par classe $\approx 0,95$). Le Tableau 9.2 et la Figure 9.10 détaillent ces scores.

TABLE 9.2 – Résultats VLM (Qwen2.5-VL-7B + LoRA) sur le jeu de test.

Classe	Precision	Recall	F1
Glioma	0,941	0,950	0,945
Meningioma	0,959	0,940	0,949
Pituitary Tumor	0,960	0,950	0,955
Accuracy globale	0,947		




FIGURE 9.10 – Matrice de confusion — Qwen2.5-VL-7B + LoRA (jeu de test, $n = 300$).

Ce résultat dépasse le benchmark ML (92,0 %) et le meilleur CNN pur (93,5 %), tout en ouvrant la voie à des sorties textuelles explicatives — avantage propre aux VLMs par rapport aux classifieurs traditionnels. L’exploration reste toutefois préliminaire (un seul modèle, fine-tuning léger, pas de validation statistique formelle).

3 Synthèse

Les deux notebooks confirment que des représentations apprises (CNN, VLM) peuvent égaler ou dépasser le pipeline manuel sur ce dataset, en particulier lorsque les branches hybrides combinent CNN et descripteurs optimisés. Le VLM apporte en outre une capacité générative (classification + justification textuelle) absente des approches ML et CNN classiques.

Les limites demeurent : dépendance GPU, faible volume de données, absence de segmentation 3D et protocole d’évaluation moins exhaustif que la Phase 2. Une fusion ML + DL + VLM, avec validation multicentrique, constituerait la suite logique de ce travail.

Conclusion Générale

Bilan du projet

Ce projet avait pour objectif de développer un système de classification automatique des tumeurs cérébrales à partir d'images IRM, en s'appuyant sur une démarche rigoureuse d'ingénierie des caractéristiques et d'évaluation expérimentale.

L'approche proposée a couvert l'ensemble de la chaîne méthodologique : prétraitement des images, extraction de descripteurs complémentaires, optimisation des paramètres, construction d'ensembles de caractéristiques, benchmark de plusieurs algorithmes et validation statistique des résultats.

Le travail réalisé montre qu'une approche de Machine Learning classique, lorsqu'elle est conçue de manière structurée et systématique, peut atteindre un niveau de performance élevé tout en conservant une bonne interprétabilité.

Résultats obtenus

Les expérimentations menées sur les 8 ensembles de caractéristiques et les 8 modèles évalués montrent une hiérarchie claire des performances.

La meilleure configuration est obtenue avec **SVM + Full(opt)**, qui atteint une Accuracy de 0,920 et un F1-Macro de 0,920 sur l'ensemble de test. Cette performance est confirmée par les analyses de robustesse (Bootstrap, Kappa, tests statistiques) présentées au Chapitre 7.

L'étude par branche met en évidence la forte contribution des descripteurs structurels (HOG), tandis que la fusion multi-caractéristiques apporte un gain supplémentaire en exploitant la complémentarité entre informations statistiques, texturales, fréquentielles et géométriques.

Au-delà du score final, le projet fournit donc une compréhension fine de l'impact de chaque famille de caractéristiques sur la qualité de la classification.

Contributions

Les principales contributions de ce travail peuvent être résumées comme suit :

- mise en place d'un pipeline complet et reproductible pour la classification de tumeurs cérébrales par IRM ;
- optimisation systématique des descripteurs (GLCM, LBP, DWT, HOG) via une phase dédiée de recherche d'hyperparamètres ;
- comparaison exhaustive de huit modèles de Machine Learning sur huit ensembles de caractéristiques, avec un leaderboard global ;
- validation statistique avancée des résultats (Cohen's Kappa, intervalles Bootstrap, McNemar, Friedman) ;
- analyse d'interprétabilité par importance de branches, permettant de relier les performances aux types d'information visuelle exploités.

Ces apports confèrent au projet une valeur à la fois applicative et méthodologique.

Perspectives

Les perspectives identifiées s'inscrivent dans la continuité directe des résultats obtenus.

Une première direction consiste à étendre le benchmark vers des approches de Deep Learning (VGG, ResNet, EfficientNet, Vision Transformers) afin de comparer de manière contrôlée les représentations manuelles et profondes.

Une deuxième direction porte sur l'intégration de modèles Vision-Language capables de produire, en plus d'une classe prédite, des explications médicales textuelles structurées. Les stratégies de fine-tuning efficient (LoRA) et d'apprentissage guidé (Teacher Forcing) constituent ici des leviers prometteurs.

Enfin, la perspective la plus ambitieuse est la construction d'un **framework hybride** combinant Handcrafted Features, Deep Features et VLMs dans une architecture multimodale unifiée. Une telle approche permettrait d'évoluer d'un classificateur performant vers un système d'aide au diagnostic plus complet, capable de **prédire, justifier et expliquer** ses décisions de façon exploitable par les professionnels de santé.

Bibliographie

- [1] B. B. PATTANAIK, K. ANITHA, S. RATHORE, P. BISWAS, P. K. SETHY et S. K. BEHERA. “Brain Tumor Magnetic Resonance Images Classification Based on Machine Learning Paradigms”. In : *Contemporary Oncology (Współczesna Onkologia)* 26.4 (2022). Fine KNN + GLCM+HOG+LBP ; 91.1% (4 classes), AUC 0.96, p. 268-274.
- [2] S. AFZAL et al. “Brain Tumor Classification Using ResNet18 with Transfer Learning and CART-ANOVA Hyperparameter Optimization”. In : (*à compléter*) (2024). Précision 99.65% (4 classes), 98.05% (7 classes).
- [3] Z. ULLAH, M. JAMJOM, M. THIRUMALAISAMY, S. H. ALAJMANI, F. SALEEM, A. SHEIKH-AKBARI et U. A. KHAN. “A Deep Learning Based Intelligent Decision Support System for Automatic Detection of Brain Tumor”. In : *Biomedical Engineering and Computational Biology* 15 (2024), p. 1-13.
- [4] N. ULLAH, J. A. KHAN, M. S. KHAN, W. KHAN, I. HASSAN, M. OBAYYA, N. NEGM et A. S. SALAMA. “An Effective Approach to Detect and Identify Brain Tumors Using Transfer Learning”. In : *Applied Sciences* 12.11 (2022), p. 5645.
- [5] A. YOUNIS et al. “Brain Tumor Detection Using a Fine-Tuned VGG-16 and Ensemble Transfer Learning Framework”. In : (*à compléter*) (2024). VGG-16 : 98.5% de précision, 94.5% de rappel, 92.6% de F1.
- [6] H. A. SHAH et al. “A Robust Approach for Brain Tumor Detection in Magnetic Resonance Images Using Fine-Tuned EfficientNet-B0”. In : (*à compléter*) (2024). Précision de validation 98.87%, AUC 0.988.
- [7] C. GUNASUNDARI et K. SELVA BHUVANESWARI. “A Novel Approach for the Detection of Brain Tumor and Its Classification via Independent Component Analysis”. In : *Scientific Reports* 15 (2025), p. 8252.
- [8] M. M. BADŽA et M. Č. BARJAKTAROVIĆ. “Classification of Brain Tumors from MRI Images Using a Convolutional Neural Network”. In : *Applied Sciences* 10.6 (2020), p. 1999.
- [9] M. M. ZAHOOR, S. A. QURESHI, S. BIBI, S. H. KHAN, A. KHAN, U. GHAFOOR et M. R. BHUTTA. “A New Deep Hybrid Boosted and Ensemble Learning-Based Brain Tumor Analysis Using MRI”. In : *Sensors* 22.7 (2022), p. 2726.
- [10] J. DIXON, O. AKINNIYI, A. ABDELHAMID, G. A. SALEH, M. M. RAHMAN et F. KHALIFA. “A Hybrid Learning-Architecture for Improved Brain Tumor Recognition”. In : *Algorithms* 17.5 (2024), p. 221.
- [11] I. PACAL et al. “A Novel Swin Transformer Approach Utilizing Residual Multi-Layer Perceptron for Diagnosing Brain Tumors”. In : (*à compléter*) (2024). Précision 99.92%, F1 99.89%.
- [12] (. à COMPLÉTER). “Machine Learning and Deep Learning for Brain Tumor MRI Analysis : A Systematic Review”. In : *Diagnostics* 15.21 (2025), p. 2692.
- [13] M. BASTHIKODI, M. CHAITHRASHREE, B. M. AHAMED SHAFEEQ et A. PRABHU GURPUR. “Enhancing Multiclass Brain Tumor Diagnosis Using SVM and Innovative Feature Extraction Techniques”. In : *Scientific Reports* 14 (2024). SVM + HOG + LBP + PCA ; 96.03% (4 classes), p. 26023.

- [14] K. KUMAR, K. JYOTI et K. KUMAR. “Machine Learning for Brain Tumor Classification : Evaluating Feature Extraction and Algorithm Efficiency”. In : *Discover Artificial Intelligence* 4 (2024). Random Forest + Image Loading/HOG/LBP ; 99% (binaire), p. 112.
- [15] R. MUTHAIYAN et M. MALLESWARAN. “Bendlets and Ensemble Learning Based MRI Brain Classification System”. In : *Intelligent Automation & Soft Computing* 33.2 (2022). Bendlets + Ensemble (kNN/NB/SVM) ; 99.5% et 99% (binaire, 2 étapes), p. 891-907.